

На правах рукописи



КОЖЕМЯКИНА ОЛЬГА ЮРЬЕВНА

**ПРОГРАММНАЯ СИСТЕМА КОМПЛЕКСНОГО АНАЛИЗА
РУССКИХ ПОЭТИЧЕСКИХ ТЕКСТОВ:
МОДЕЛИ И АЛГОРИТМЫ**

Специальность 05.13.17 — Теоретические основы информатики

АВТОРЕФЕРАТ
диссертации на соискание ученой степени
доктора технических наук

Новосибирск — 2022

Работа выполнена в Федеральном государственном бюджетном научном учреждении «Федеральный исследовательский центр информационных и вычислительных технологий»

Научный консультант:

Барахнин Владимир Борисович

доктор технических наук, доцент, ведущий научный сотрудник лаборатории информационных ресурсов Федерального государственного бюджетного научного учреждения «Федеральный исследовательский центр информационных и вычислительных технологий» (ФИЦ ИВТ)

Официальные оппоненты:

Ронжин Андрей Леонидович

доктор технических наук, профессор, профессор РАН, директор Федерального государственного бюджетного учреждения науки «Санкт-Петербургский Федеральный исследовательский центр Российской академии наук»

Лукашевич Наталья Валентиновна

доктор технических наук, ведущий научный сотрудник лаборатории анализа информационных ресурсов Научно-исследовательского вычислительного центра Федерального государственного бюджетного образовательного учреждения высшего образования «Московский государственный университет имени М.В. Ломоносова»

Пальчунов Дмитрий Евгеньевич

доктор физико-математических наук, доцент, ведущий научный сотрудник лаборатории теории вычислимости и прикладной логики Федерального государственного бюджетного учреждения науки Института математики им. С.Л. Соболева Сибирского отделения Российской академии наук

Ведущая организация:

Федеральное государственное учреждение «Федеральный исследовательский центр «Информатика и управление» Российской академии наук» (ФИЦ ИУ РАН)

Защита состоится «22» сентября 2022 года в 14 ч. 00 мин. на заседании диссертационного совета Д219.005.02 в Федеральном государственном бюджетном образовательном учреждении высшего образования «Сибирский государственный университет телекоммуникаций и информатики» (СибГУТИ) по адресу: 630102, г. Новосибирск, ул. Кирова, 86, ауд. 625.

С диссертацией можно ознакомиться в библиотеке СибГУТИ и на сайте:
https://sibsutis.ru/science/postgraduate/dis_sovets/

Автореферат разослан « » 20 г.

Ученый секретарь
диссертационного совета,

д.т.н., доцент



И.В. Нечта

ОБЩАЯ ХАРАКТЕРИСТИКА РАБОТЫ

Актуальность исследования.

Современный подход к исследованию текстовых сообщений предполагает использование многоуровневой модели информации. В художественных текстах, прежде всего, поэтических, уровни структуры произвольного сообщения имеют устойчивую иерархию: метрика, ритмика, фонетика, лексика, грамматика, литературный стиль, тематика, литературный жанр. При этом уровни структуры произвольного сообщения и стиха четко соотносятся: к статистическому уровню относится фонетика, к синтаксическому уровню — метрика и ритмика, к семантическому — лексика и грамматика, на границе семантического и прагматического уровней находится тематика. Процесс анализа каждого поэтического текста состоит из рассмотрения структурных уровней текста как самостоятельных смысловых единиц с последующим связыванием полученных данных с другими элементами структуры: лексика формирует семантику данного конкретного стихотворения, метрика является общим фоном семантической традиции, на которой оно воспринимается.

Одной из основных трудностей, возникающих при решении задач анализа поэтических текстов, является необходимость анализа корпуса поэтических текстов большого объема. Эта задача чрезвычайно трудоемка, поэтому, как правило, в поле зрения исследователя попадает лишь сравнительно небольшой круг стихотворений поэтов классического периода, что существенно снижает полноту анализируемого материала и, следовательно, достоверность полученных результатов. При анализе корпуса поэтических текстов большого объема возникает проблема автоматизации анализа различных уровней структуры стиха, решение которой освободит исследователя от рутинной работы, и в то же время позволит расширить круг анализируемых произведений. Наличие корреляции между уровнями структуры произвольного сообщения и стихотворения показывает, что в процессе автоматизации анализа стихотворений актуально применение информационных технологий и математических методов. Лексический анализ стихотворения предусматривает создание его лексического словаря, который используется, в частности, для выявления доминирующих частей речи, тематических (семантических) полей и поэтической фразеологии. Решение задач идентификации тематических полей и метафор требует, наряду с лексическими словарями слов и словосочетаний, еще и дополнительной, зачастую слабо формализованной информации. Грамматический анализ текста включает в себя определение возможной принадлежности фрагмента текста к именному или глагольному типу (соответственно к непрерывным именным предложениям или перечислению действий), а также временного плана и предметной структуры стихотворения (что требует изучения использования категорий времени, залога и лица), именные и глагольные типы, в свою очередь, определяются прямым анализом лексического словаря, либо морфологическим анализом. Чтобы определить использование категорий времени, залога и лица, необходимо дополнительно использовать морфологические правила русского языка, позволяющие установить конкретные категории. При этом исследование зависимости тематики от нижних уровней стихотворной структуры является одним из наименее изученных направлений в анализе поэтических текстов. Использование методов статистического анализа корпусов поэтических текстов большого объема также может быть эффективным методом решения этих и подобных проблем. Важным направлением современных исследований является многомерный анализ семантических, эмоциональных и прочих характеристик текстов, масштабное применение которого практически невозможно без использования программных систем. Работа с большими текстовыми корпусами предполагает также и использование методов интеллектуального анализа данных.

Таким образом, тематика диссертационной работы, связанная с созданием программной системы автоматизированного многоуровневого анализа поэтических текстов, обеспечивающей обработку больших корпусов поэтических текстов с целью извлечения метаданных, соответствующих разным уровням представления информации, и ориентированной

на выявление взаимозависимостей между структурами уровней, может быть охарактеризована как актуальная проблема в области создания систем автоматизированной обработки текстов.

Степень разработанности темы исследования. Разработки А. А. Маркова (старшего), исследования А. Н. Колмогорова, труды М. Л. Гаспарова по выразительным средствам поэтического языка — классические методы, успешно зарекомендовавшие себя в области количественного анализа текстов. Теоретические исследования в области языкознания, ставшие основой большинства современных алгоритмов автоматического анализа текстов на русском языке, представлены в работах А. А. Зализняка, Ю. Д. Апресяна, И. А. Мельчука, О. С. Ахмановой, Е. В. Падучевой, В. А. Плунгяна, С. Е. Никитиной, И. М. Богуславского и др. Работы Дж. Т. Шоу с использованием компьютера по составлению конкорданса к стихам А. С. Пушкина стали эталоном для последующих исследований, в частности, работы В. Е. Холшевникова над словарем рифм Пушкина. Отметим исследования И. И. Дроздовой и А. Д. Обухова об определении авторства текста по частотным характеристикам, исследование Е. А. Гречникова (с соавторами) о методе определения неестественного происхождения документа, основанном на изучении статистики встречаемости пар соседних слов. Некоторыми вопросами компьютерной лингвистики и исследованием различных уровней текста занимались в разные годы Ю. И. Шокин, А. М. Федотов, В. Б. Барахнин, Н. В. Лукашевич, Д. Е. Пальчунов, А. Л. Ронжин, М. К. Тимофеева, Ю. А. Загорулько, Т. В. Батура и др. Из зарубежных результатов отметим следующие исследования в области автоматизации анализа метrorитмических характеристик поэтических текстов: М. Хэйвард провел компьютерное исследование особенностей метрики в стихах различных поэтов; Д. Каплан и Д. Блей, Дж. Као и Д. Джурафски проанализировали стили американских поэтов на основе орфографических, синтаксических и фонетических характеристик их стихов; в работе А. Курта и М. Кара предложен алгоритм распознавания и анализа стихотворений, написанных в системе стихосложения аруд; система SPARSAR авторства Р. Дельмонте предполагает автоматический комплексный анализ поэтических текстов с целью изучения стиля; web-приложение Metricalizer², разработанное К. Боббенхаузенем и Б. Хаммерихом, позволяет производить автоматический анализ метрических характеристик немецких стихов; в исследовании О. Калена представлен количественный подход к поэзии, основанный на использовании нескольких статистических показателей (энтропия, информационная энергия, *n*-граммы и т.д.), применяемых к нескольким знаковым произведениям английской литературы.

Для исследований, связанных с автоматизированным анализом текста на русском языке, ситуация, следующая: если на теоретическом уровне существуют некоторые исследования по автоматической спецификации стиха в информационно-аналитической системе (В. Н. Бойков и др.), то практически реализованных, с воспроизводимыми алгоритмами, и отмеченных научными публикациями полноценных систем нет. Отдельные исследования, описывающие комплексный подход к автоматизации характеристик русских поэтических текстов, затрагивают специфические жанры поэзии, например, фольклор. Широко известны частотные словари языка поэтов-классиков, проводились многочисленные исследования статистики типов русской рифмы (в том числе, и применительно ко временной динамике); известной в своем кругу системой является незаконченный проект «Конкорданс к текстам Ломоносова», построенный на основе корпуса авторских текстов, снабженных структурной, филологической и грамматической разметкой. Несомненно, важной является работа А. В. Козьмина «Автоматический анализ стиха в системе Starling», посвященная автоматизированному определению метrorитмических характеристик русских поэтических текстов и опирающаяся на информационную систему, но эти работы были прекращены. Исследования И. А. Пильщикова и А. С. Старостина, в которых авторы используют компьютерный морфолого-акцентологический анализ, являются принципиальными по автоматизации процесса распознавания метрических характеристик текста, однако подробностей реализации алгоритма и результатов его использования авторами не приведено.

В итоге можно говорить о том, что исследования, связанные с комплексным

автоматизированным анализом поэтических текстов на русском языке, и реализующие этот комплексный анализ программные системы в настоящее время отсутствуют.

Цель диссертационного исследования: теоретическое обоснование, разработка и реализация принципов создания программных систем многоуровневого анализа поэтических текстов с целью исследования взаимозависимостей между структурами различных уровней поэтического текста.

Научно-техническая проблема, решаемая в диссертационном исследовании: теоретическое обоснование и разработка технологических основ автоматизированного многоуровневого анализа поэтических текстов за счет создания программных систем, способных извлекать из поэтических текстов их характеристики, относящиеся к различным структурным уровням, и предоставлять аппарат исследования их взаимозависимостей.

Задачи, решаемые в диссертационной работе:

Основной задачей диссертационной работы является разработка *принципов создания программных систем автоматизированного многоуровневого анализа поэтических текстов*. Решение этой задачи опирается на решение следующих основных подзадач:

1. Обоснование соответствия между уровнями многоуровневой модели информации и уровнями структуры поэтического текста.
2. Разработка структуры многоуровневого описания русского поэтического текста.
3. Разработка алгоритмов фонетического анализа стихотворно-текстовой информации.
4. Исследование принципов анализа метrorитмических и строфических характеристик текста (фактур).
5. Исследование принципов и разработка алгоритмов составления конкордансов и справочников, извлечения словосочетаний, составления словарей языка поэтов.
6. Разработка алгоритмов автоматизированного извлечения жанровых и стилевых характеристик.

Объект исследования: поэтический текст и характеристики его основных уровней, соответствующие различным уровням информации, рассматриваемые как метаданные.

Предмет исследования: принципы построения программных систем комплексного анализа поэтических текстов, модели и алгоритмы автоматизированного многоуровневого анализа поэтических текстов, методы исследования взаимозависимостей между структурами уровней поэтического текста.

Методология и методы исследования. В диссертационном исследовании использовалась методология системного анализа и теоретической информатики, как науки о структуре и свойствах семантической информации. Для решения конкретных задач применялись методы теории информации, компьютерной лингвистики, математического моделирования, статистические методы, методы машинного обучения, методы автоматической обработки текста, методы теории моделирования баз данных, а также информационные технологии.

Научная новизна. Наиболее существенные научные результаты заключаются в следующем:

— Впервые сформулированы и обоснованы принципы создания программных систем автоматизированного многоуровневого анализа поэтических текстов, предназначенных для хранения поэтических текстов и их представления посредством широкого спектра извлеченных

из них метаданных, что позволяет в автоматизированном режиме генерировать словари рифм, метроритмические справочники, словари языка поэтов, конкордансы.

— Обосновано соответствие между уровнями многоуровневой модели информации и уровнями структуры поэтического текста, отличающееся учетом специфики классического русского стихосложения, а также обеспечивающее возможность применения информационных технологий и математических методов в задаче автоматизированного комплексного анализа поэтических текстов.

— Разработана структура описания русского поэтического текста, отличающаяся многоуровневостью и наличием категориальных связей между уровнями, обеспечивающая системный анализ обрабатываемого текста и выявление взаимосвязанностей его уровней.

— Разработаны алгоритмы автоматизированного извлечения жанровых и стилевых характеристик, впервые основанные на методах машинного обучения и позволившие обеспечить точность определения жанровых и стилевых характеристик, превышающую 95%.

— Предложены алгоритмы фонетического анализа стихотворно-текстовой информации, отличающиеся использованием информации о морфологической структуре анализируемых лексем, обеспечивающие перевод поэтических текстов из дореформенной орфографии в современную с учетом сохранения фонетических свойств структуры текста.

— Исследованы принципы автоматизированного анализа метроритмических и строфических характеристик текста (фактур), впервые основанные на единстве метроритмики и строфики, обеспечивающие цельное представление о нижних уровнях поэтического текста.

— Исследованы принципы и разработаны алгоритмы составления конкордансов и справочников, извлечения словосочетаний, составления словарей языка поэтов, автоматизирующие снятие проблемы омографии, что обеспечивает семантическую точность составляемых словарей.

Работа соответствует следующим пунктам паспорта специальности 05.13.17:

2. Исследование информационных структур, разработка и анализ моделей информационных процессов и структур.

5. Разработка и исследование моделей и алгоритмов анализа данных, обнаружения закономерностей в данных и их извлечениях разработка и исследование методов и алгоритмов анализа текста, устной речи и изображений.

6. Разработка методов, языков и моделей человеко-машинного общения; разработка методов и моделей распознавания, понимания и синтеза речи, принципов и методов извлечения данных из текстов на естественном языке.

14. Разработка теоретических основ создания программных систем для новых информационных технологий.

Достоверность и обоснованность научных положений, результатов и выводов, приведенных в диссертационной работе, обеспечиваются применением надежных методов исследования, корректностью использования адекватного математического аппарата и подтверждены результатами использования предложенных информационных моделей и структур при создании системы автоматизированного комплексного анализа русских поэтических текстов, программной системы «Стемматизация и генерация словоформ казахского языка», актами внедрения полученных результатов в научно-исследовательские работы и учебные процессы, а также апробацией и обсуждением результатов работы на международных и всероссийских конференциях, рецензированием и предварительной экспертизой научных статей, опубликованных в ведущих научных изданиях.

Теоретическая значимость. Полученный в работе комплекс теоретических результатов, обобщений и исследований позволил решить научно-техническую проблему теоретического обоснования и разработки технологических основ создания программных систем, способных

в автоматизированном режиме извлекать из поэтических текстов их характеристики, относящиеся к различным структурным уровням, и исследовать их взаимозависимость.

Практическая значимость и внедрение. На основе полученных в работе теоретических результатов и методических рекомендаций создан комплекс методов и алгоритмов, обеспечивающий решение важной научно-технической задачи: теоретического обоснования и разработки технологических основ создания программных систем, способных в автоматизированном режиме извлекать из поэтических текстов их характеристики, относящиеся к различным структурным уровням, и исследовать их взаимозависимость.

Результаты работы использованы при выполнении проекта 122010800027-7 (ЕГИСУ) (2022-01-01 — 2024-12-31) в рамках базовой темы «Разработка, создание и исследование распределенных информационных систем для поддержки принятия решений и автоматизации процессов», при выполнении проекта 122010800027-7 (ЕГИСУ) (2020-01-01 — 2020-12-31) в рамках базовой темы «Разработка, создание и исследование распределенных информационных систем для поддержки принятия решений и автоматизации процессов», при выполнении проекта АААА-А17-117120670141-7 (2017-01-01 — 2020-12-31) в рамках базовой темы «Теоретические основы, алгоритмическое обеспечение и информационные технологии для решения фундаментальных и прикладных задач исследования сложных техногенных, природных и биологических систем», проекта IV.38.1.1 (2012-01-01 — 2016-12-31) в рамках базовой темы «Создание технологий, алгоритмов и интегрированных систем информационно-вычислительной поддержки решения задач интеллектуального анализа и обработки потоков данных на основе распределенных гетерогенных ресурсов и “облачных” вычислений», при выполнении проекта 19-18-00466 (2019-05-01 — 2021-12-31) Российского научного фонда «Разработка и реализация информационной системы многоуровневого исследования стихотворных текстов», при выполнении проекта PRAS-2016-0015 (2016-01-01 — 2017-12-31) «Автоматизированное определение жанрового типа и стилистической окраски текстов на русском языке» в рамках Программ Президиума РАН, при выполнении проекта 43 в рамках Комплексного интеграционного проекта СО РАН «Модели и методы создания информационных систем, интегрирующих географическую и временную составляющие документов, согласованных с мировыми стандартами и тенденциями развития национальной и международной информационной инфраструктуры, интегрированных в открытое семантическое пространство», при выполнении проекта 19-37-90019 (2019-10-01 — 2020-01-01) Российского фонда фундаментальных исследований «Разработка моделей хранения метаданных русских художественных текстов в тематических базах данных и технологий их отображения», при выполнении проекта 13-07-00258-а (2013-01-01 — 2015-12-31) Российского фонда фундаментальных исследований «Разработка моделей и алгоритмов, предназначенных для извлечения фактов из массивов естественно-языковых слабо структурированных текстовых документов», при выполнении проекта ПЦФ № BR05236839 «Разработка информационных технологий и систем для стимулирования устойчивого развития личности как одна из основ развития цифрового Казахстана».

Результаты работы внедрены в системе комплексного анализа русских поэтических текстов, созданной в Федеральном исследовательском центре информационных и вычислительных технологий; в программной системе «Стемматизация и генерация словоформ казахского языка», созданной в Институте информационных и вычислительных технологий Комитета науки Министерства образования и науки Республики Казахстан; в деятельность Лаборатории цифровых исследований Института русской литературы (Пушкинский дом) Российской академии наук; при проведении научных исследований лаборатории интеллектуальных систем Института автоматизации и процессов управления Дальневосточного отделения Российской академии наук; в учебный процесс кафедры математического моделирования Новосибирского государственного университета.

Основные положения, выносимые на защиту.

Технологические основы создания программных систем, способных в автоматизированном режиме извлекать из поэтических текстов их характеристики, относящиеся к различным структурным уровням, и исследовать их взаимозависимость, включающие в себя:

— структуру описания русского поэтического текста, отличительной особенностью которой является многоуровневость и наличие категориальных связей между уровнями;

— модель программной системы комплексного анализа поэтических текстов, предназначенную для хранения и извлечения широкого спектра метаданных, позволяющую в автоматизированном режиме генерировать словари рифм, метроритмические справочники, словари языка поэтов, конкордансы;

— принципы и алгоритмы автоматизации анализа основных уровней русского поэтического текста, позволяющие извлекать широкий спектр метаданных, в том числе специфических для поэтических текстов.

Апробация результатов исследования.

Основные положения диссертации обсуждались на многих международных, всероссийских и региональных конференциях, в том числе на Всероссийской научной конференции RCDL-2012 «Электронные библиотеки: перспективные методы и технологии, электронные коллекции» (Переславль-Залесский, 2012), на Международной конференции «Информационно-вычислительные технологии и математическое моделирование» (Кемерово, 2012), на Международной конференции ВИТ-2013 «Вычислительные и информационные технологии в науке, технике и образовании» (Усть-Каменогорск, Казахстан, 2013), на Российской конференции с международным участием DICR-2014 «Распределенные информационно-вычислительные ресурсы» (Новосибирск, 2014), на VI Международной конференции «Системный анализ и информационные технологии» САИТ-2015 (Светлогорск, 2015), на Международной конференции «Computational and Informational Technologies in Science, Engineering and Education» CITech-2015 (Алма-Ата, Казахстан, 2015), на XVII Международной конференции DAMDID/RCDL-2015 «Аналитика и управление данными в областях с интенсивным использованием данных» (Обнинск, 2015), на XIV Международной конференции «Information Technologies and Management» (Рига, Латвия, 2016), на Международной конференции EEIA-2016 «Education Environment for the Information Age» (Москва, 2016), на IV Международной конференции «Современные информационные технологии для научных исследований в области наук о Земле» ITES-2016 (Южно-Сахалинск, 2016), на Международной конференции «Математические и информационные технологии» МИТ-2016 (Врнячка Баня, Будва — Сербия, Черногория, 2016), на Международной научной конференции «Информатика и прикладная математика», посвященной 25-летию независимости Республики Казахстан и 25-летию Института информационных и вычислительных технологий (Алматы, Казахстан, 2016), на XVII Международной конференции DAMDID/RCDL-2016 «Аналитика и управление данными в областях с интенсивным использованием данных» (Звенигород, 2016), на XV Международной конференции «Information Technologies and Management» IT&M2017 (Рига, Латвия, 2017), на Международной конференции по психологии и образованию ICPE 2017 (Москва, 2017), на VII Международной конференции «Системный анализ и информационные технологии» САИТ-2017 (Светлогорск, 2017), на II Международной научной конференции «Информатика и прикладная математика» (Алматы, Казахстан, 2017), на XIX Международной конференции DAMDID/RCDL-2017 «Аналитика и управление данными в областях с интенсивным использованием данных» (Москва, 2016), на XVI Российской конференции «Распределенные информационно-вычислительные ресурсы Наука — цифровой экономике» DICR-2017 (Новосибирск, 2017), на XVI Международной конференции «Information Technologies and Management» IT&M2018 (Рига, Латвия, 2018), на Международной конференции по психологии и образованию ICPE 2018 (Москва, 2018), на III Международной научной конференции «Информатика и прикладная математика» (Алматы, Казахстан, 2018),

на Международной научно-практической конференции «Наука, технологии и информация в библиотеках» (Новосибирск, 2018), на XVII Международной конференции «Information Technologies and Management» IT&M2019 (Рига, Латвия, 2019), на XIII Международной научно-практической конференции «Современные технологии и ИТ-образование» Москва, 2018), на VIII Международной конференции «Системный анализ и информационные технологии» САИТ-2019 (Иркутск, 2019), на Международной конференции Big Data and Artificial Intelligence Conference 2019 (Москва, 2019), на IV Международной научной конференции «Информатика и прикладная математика» (Алматы, Казахстан, 2019), на XXI Международной конференции DAMDID/RCDL-2019 «Аналитика и управление данными в областях с интенсивным использованием данных» (Казань, 2019), на XVII Международной конференции «Распределенные информационно-вычислительные ресурсы: Цифровые двойники и большие данные» DICR-2019 (Новосибирск, 2019), на XVIII Международной конференции «Information Technologies and Management» IT&M2020 (Рига, Латвия, 2020), на VI Международной конференции «Информационные технологии и нанотехнологии» ИТНТ-2020 (Самара, 2020), на Международной конференции Big Data and Artificial Intelligence Conference 2020 (Москва, 2020), на Международной конференции «Вычислительные и информационные технологии в науке, технике и образовании» CITech-2020 (Алматы, Казахстан, 2020), на XXIII Международной конференции DAMDID/RCDL-2021 «Аналитика и управление данными в областях с интенсивным использованием данных» (Москва, 2021), на XIII Международной научной конференции Inverse and Ill-Posed Problems: Theory and Numerics (Новосибирск, 2021), на Международной конференции Информационные технологии, сети и телекоммуникации» ITN&T-2021 (Ургенч, Узбекистан, 2021), на VII Ежегодной встрече Ассоциации Информационных систем (The Association for Information Systems (AIS): 7th Annual Meeting of SIG BD (The Special Interest Group for Big Data Application), International Research Workshop on Big Data Application for Decision Making) (2021), а также на семинарах и совещаниях в Федеральном исследовательском центре информационных и вычислительных технологий, Институте систем информатики СО РАН им. А.П. Ершова, Новосибирском государственном университете, а Институте филологии СО РАН, в МИРЭА — Российском технологическом университете, на Общероссийском семинаре «Информатика, управление и системный анализ».

Публикации. Результаты диссертации опубликованы в 30 работах (список приведен в конце автореферата), включая 9 статей в журналах, рекомендованных ВАК РФ [1—9], 11 статей в изданиях, индексируемых Web of Science и/или Scopus [10—20], в 7 статьях в других изданиях [21—27]. Получено 2 свидетельства о государственной регистрации программы для ЭВМ [28, 29], свидетельство о государственной регистрации базы данных [30].

Личный вклад автора. В работах, выполненных в соавторстве, О. Ю. Кожемякиной принадлежат результаты, относящиеся к:

— разработке технологических основ создания программных систем, способных в автоматизированном режиме извлекать из поэтических текстов их характеристики, относящиеся к различным структурным уровням, и исследовать их взаимозависимость; к разработке структуры описания русского поэтического текста, отличительной особенностью которой является многоуровневость и наличие категориальных связей между уровнями;

— созданию модели программной системы комплексного анализа поэтических текстов, предназначенной для хранения и извлечения широкого спектра метаданных, позволяющей в автоматизированном режиме генерировать словари рифм, метроритмические справочники, словари языка поэтов, конкордансы;

— разработке принципов и алгоритмов автоматизации анализа основных уровней русского поэтического текста, позволяющих извлекать широкий спектр метаданных, в том числе специфических для поэтических текстов.

Структура и объем диссертации.

Диссертация состоит из введения, 7 глав, заключения, списка использованных источников из 264 наименований, списка публикаций автора, приложения (в том числе 3 свидетельства о РИД и 3 актов о внедрении). Общий объем работы 288 страниц, включая 30 рисунков и 33 таблицы.

ОСНОВНОЕ СОДЕРЖАНИЕ ДИССЕРТАЦИИ

Во **введении** обосновывается актуальность диссертационной работы, сформулированы цели, задачи, объект и предмет исследования, указаны методы исследования, приведена научная новизна, дана общая характеристика работы.

Соответствие между уровнями многоуровневой модели информации и уровнями структуры поэтического текста получает в работе обоснование с учетом отличительных особенностей системы классического русского стихосложения, а также с учетом специфических категорий, присущих каждому уровню структуры. Категориальные связи между уровнями структуры поэтического текста позволяют обеспечить системный анализ обрабатываемого текста и выявить взаимозависимости уровней структуры.

В **первой главе** содержится обзор применения количественных методов в исследованиях русской поэзии, рассматриваются существующие системы лингвистического анализа для некоторых языков, а также алгоритмы и методы, лежащие в их основе. Обзор методологии с акцентами на методах, использованных при разработке системы комплексного анализа русских поэтических текстов, призван осветить традиции применения количественных методов в исследованиях русской поэзии для понимания постановки решаемых нами задач.

Показано становление и развитие применения количественных методов в исследованиях русской поэзии. Алгоритмы и системы анализа низших уровней поэтических текстов, предлагаемые в зарубежных работах, весьма зависят от особенностей конкретного языка и, что ожидаемо, плохо применимы для анализа поэтических текстов на русском языке. Однозначно определяется, что разработка универсального инструмента для автоматического анализа поэтических текстов весьма затруднительна по этой же причине: хотя ряд разработок показывает определенную возможность анализа для языков с некоторыми идентичными признаками, но инструменты, которые анализируют более одного языка, являются редким исключением при анализе текстов (в том числе поэтических) и зависят от близости языков. Однако, в рамках данной работы предприняты достаточно успешные попытки применить алгоритмы, разработанные для русского языка, как языка с очевидной фонетикой, фиксированным ударением, а также отсутствием редукции, к текстам на казахском языке. Алгоритмы стемматизации и генерации существительных, прилагательных и глаголов казахского языка (что, в свою очередь, полностью решает задачу анализа и синтеза словоформ для научно-технических текстов на казахском языке) продемонстрировали работоспособность даже для языка из другой языковой семьи, важную роль в этом сыграла общность в структуре.

Рассмотрены существующие системы для некоторых языков, а также алгоритмы и методы, лежащие в их основе, при этом стоит отметить возрастающий интерес к лингвистическому анализу в последние десятилетия, что обусловлено развитием методов машинного обучения, потенциально применяемых в области анализа текстов. Среди новейших работ стоит отметить статью О. Калена (2020), в которой представлен количественный подход к поэзии, основанный на использовании нескольких статистических показателей (энтропия, информационная энергия, n -граммы и т.д.), применяемых к нескольким знаковым произведениям английской литературы.

Обзор исследований, связанных с автоматизированным анализом поэтических текстов на русском языке, и апробированных комплексных систем подтверждает актуальность и новизну разработанной в диссертационном исследовании программной системы.

Вторая глава посвящена вопросам, связанным с разработкой алгоритмов фонетического анализа стихотворно-текстовой информации, отличающихся использованием информации о морфологической структуре анализируемых лексем. Такой подход позволяет обеспечить перевод поэтических текстов из дореформенной орфографии в современную с учетом сохранения фонетических свойств структуры текста, что принципиально важно для процессов фонетического уровня анализа текста.

Поставлена задача разработки алгоритмов перевода поэтических текстов из дореформенной орфографии в современную, актуальность которой выявилась в процессе исследований, поскольку использование существующих онлайн-сервисов по переводу из старой орфографии в рамках полноценного программного комплекса, подразумевающего автоматическую обработку больших корпусов текстов, довольно затруднительно.

Представлен разработанный и реализованный алгоритм перевода текстов из дореформенной орфографии в современную с учетом морфологии слов, отличительной особенностью которого является двухэтапный перевод слова:

- 1) поиск и исправление правописания морфемы;
- 2) поиск и исправление оставшихся букв. Второй этап алгоритма подразумевает простую замену устаревшей буквы на современный ей эквивалент, однако правописание морфем, рассматриваемых на первом этапе, не столь тривиально.

Изучены и протестированы основные алгоритмы морфологического анализа слов: из наиболее популярных алгоритмов морфологического анализа для русского языка самые точные результаты дает библиотека для языка Python — *py morphology2*, позволяющая получить морфологические данные для каждого слова: лемму входного слова, его частеречную принадлежность, значения грамматических категорий в соответствии с определенной частью речи. При оценке результатов тестирования выявлены закономерности в ошибках, допускаемых *py morphology2*, которые далее были использованы при адаптации данного анализатора к работе с дореформенной орфографией. На основе выявленных зависимостей между правилами дореформенного и современного правописания описаны формальные правила перевода.

Показана адаптация библиотеки *py morphology2* к работе с дореформенной орфографией. Для повышения точности работы *py morphology2* с текстами в дореформенной орфографии предложен метод, заключающийся в том, что сначала производится временная замена окончания на его современный эквивалент, что приводит либо к успешному получению современной формы слова, либо к получению несуществующего или другого (нового) слова. При успешной замене морфологические характеристики слова соответствуют ожидаемым, иначе замена приводит к изменению самого слова, поэтому характеристики будут отличаться от ожидаемых, в таком случае слово будет преобразовано к исходному виду. Анализатор *py morphology2* возвращает все возможные варианты морфологического разбора, каждый из них имеет оценку вероятности того, что он является правильным: вариант разбора, оценка которого наиболее высока, оказывается верным примерно в 79% случаев, однако этого недостаточно, поэтому разработанный алгоритм перевода учитывает все возможные варианты.

Определена точная последовательность шагов алгоритма для каждой группы слов, объединенных по морфологическому признаку, учитывающая особенности изменения правописания приставок и разнообразных падежных окончаний (основных групп орфографических изменений).

I. Для приставок (из-, воз-/вз-, раз-/роз-, низ-, без-, через-/чрез-):

1. Ищем вхождение приставки в слово.
2. Если это приставка из первых четырех, проверяем следующую букву.
 - 2.1. Если следующая буква *с*, то замена *з* в приставке на *с*.
 - 2.2. Иначе — без изменений.
3. Иначе определяем глухость/звонкость следующей после нее буквы.
 - 3.1. Если глухая — замена на *с*.
 - 3.2. Иначе — без изменений.

II. Для падежных окончаний существительных (-ию, -ью: III скл., тв.п.):

1. В случае с *-ью* оставляем слово без изменений.
2. Иначе:
 - 2.1. Ищем вхождение *-ию* с конца и заменяем на *-ью*.
 - 2.2. Подаем слово с заменой на вход анализатору.
 - 2.3. Если это существительное III скл. (т.е. ж.р. и лемма оканчивается на *-ь*) в тв.п., то сохраняем замену окончания, иначе — возвращаем *-ию*.

III. Для падежных окончаний прилагательных (*-ья, -ия*: мн.ч., ж.р.):

1. Ищем вхождение *-ья/ия* с конца.
2. Заменяем *-ья/-ия* на *-ье/-ие* соответственно.
3. Подаем слово с заменой на вход анализатору.
4. Находим вариант разбора, в котором часть речи определена как прилагательное, а число — множественное.
5. Если не найден такой вариант, то возвращаем *-ья/-ия* — перевод не нужен, следующие шаги не выполняются. Иначе — переход к шагу 6.
6. Отдаем на вход анализатору лемму в выбранном разборе.
7. Если слово — прилагательное и действительно является леммой (т. е. м.р., ед.ч., им.п.), то сохраняем замену окончания, иначе — возвращаем *-ья/-ия*.

IV. Для падежных окончаний существительных (*-ье*: ср.р., II скл., п.п.), поскольку окончание *-ьи* может быть у слов, лемма которых оканчивается на *-ье*, алгоритм приобретает вид:

1. Находим вхождение *-ьи* с конца.
2. Заменяем на *-ье*.

Однако, в режиме работы с поэтическим текстом, где допустима форма с *-ьи* для существительных, лемма которых оканчивается на *-ие*, имеем следующие шаги алгоритма:

1. Ищем вхождение *-ьи* с конца.
2. Заменяем на *-ье*.
3. Подаем слово с заменой на вход анализатору.

Если лемма оканчивается на *-ье*, то сохраняем замену, иначе (если лемма оканчивается на *-ие*) — возвращаем *-ьи*.

V. Для прилагательных / местоимений / причастий / числительных (*-ый, -ий*: р.п./в.п., м.р./ср.р.):

1. Ищем вхождение с конца *-аго/-яго*.
2. Если слово находится в словаре анализатора, то пропускаем это слово без изменений. Иначе — переход к шагу 3.
3. Если *-аго*:
 - 3.1. если предыдущая буква шипящая, то замена на *-его*;
 - 3.2. иначе — *-ого*;
4. Если *-яго*, то замена на *-его*.
5. Подаем слово с заменой на вход анализатору.
6. Находим разбор, в котором одновременно совпадают признаки, вынесенные в заголовок (часть речи, падеж и род). Подаем лемму из разбора на вход анализатору и переходим к шагу 7, если найдено, иначе — возвращаем *-аго/-яго* — перевод не требуется.

7. Если выделенная лемма действительно ей является, т. е. слово находится в начальной форме, и определена как соответствующая часть речи, то сохраняем замену, иначе — возвращаем *-аго/-яго*.

VI. Онѣ, однѣ, однѣхъ, однѣмъ, однѣми: хранение в словаре с верной заменой (буква *и*), замена на эквивалент путем обращения к словарю.

VII. Ея (нея) (притяжательное местоимение, р.п.): замена на эквивалент путем обращения к словарю; если используется режим без *ѣ*, то замена на *ее* (*нее*), иначе — *еѣ* (*неѣ*).

VIII. Ее (*нее*) (местоимение, в.п.): замена на эквивалент путем обращения к словарю; если используется режим без *ѣ*, то замена не производится, иначе — *еѣ* (*неѣ*).

В ходе тестирования рассчитана точность перевода в режимах работы (поэтический режим и режим поддержки буквы ё) с различными видами текстов (художественный поэтический, художественный прозаический и нехудожественный), которая оказалась близка к 100 %.

Третья глава посвящена теоретическому обоснованию понятия фактуры, как структурной модели поэтического текста, разработке математической модели фактуры, принципам автоматизированного анализа метроритмических и строфических характеристик, определяющих фактуру, а также подходам к составлению метрических справочников. Принципы автоматизированного анализа метроритмических и строфических характеристик впервые основаны на единстве метроритмики и строфики поэтического текста в рамках понятия об его фактуре, что обеспечивает цельное представление о нижних уровнях структуры текста.

Дано определение фактуры, приведена математическая модель фактуры и определены типы фактур. Фактуры, учитывающие строфику и метроритмику, являются базисной единицей анализа характеристик фонометрического уровня поэтического текста. Фактура стихотворения в целом — это фактура входящих в него строф в предположении, что оно равно строфическое. Фактура является структурной моделью поэтического текста, определяется как совокупность метроритмических характеристик и однозначно определяет метроритмический и строфический шаблон стихотворного текста.

Математической моделью фактуры является вектор характеристик $Facture = [k, M, St]$, учитывающий и отражающий все рассматриваемые метроритмические характеристики текста:

- 1) k — стопность (целочисленное значение или особые символы для вольного стиха (В), дольника (дол) и т. п.);
- 2) M — метр (элемент из множества {хорей (х), ямб (я), дактиль (д), амфибрахий (ам), анапест (ан), дольник (дол)});
- 3) St — строфика (слово из символов латинского или греческого алфавита в соответствии с правилами из справочника).

Автоматизированное определение фактур включает следующие этапы:

1. На основании данных «Метрического справочника к стихотворениям А. С. Пушкина» (1934) составлена полная таблица примеров фактур, используемых Пушкиным в равно строфических моно метрических поэтических текстах. Таблица состоит из индексов: уникальный номер фактуры; метр; стопность; строфика; пример строфы с такой фактурой; номер примера в издании собраний сочинений А. С. Пушкина (1930-1931); год написания стихотворения с соответствующей фактурой.
2. Проведен анализ полученных результатов, выявлены и учтены неточности, допущенные в Метрическом справочнике.
3. Сведения, представленные в таблице, занесены в базу данных с присвоением каждой фактуре уникального индекса.
4. Разработан алгоритм определения фактуры, на его основе реализована программа на языке Python, определяющая фактуру входного стихотворения.
5. Результаты работы программы представляются в текстовом формате, в формате JSON, в формате CSV.

Дано описание модели метра и стопности, а также решение проблемы неоднозначной акцентуации. Исследованы метроритмические характеристики текста в контексте основополагающих принципов автоматизированного комплексного анализа поэтических текстов, выявлена основная сложность при автоматизированном анализе метроритмических характеристик — «неидеальная» акцентуация слов, а также другие особенности поэтической строки.

Для разрешения этих ситуаций используется алгоритм расстановки ударений методом «по аналогии», разработанный И. В. Кузнецовой (В. Б. Барахнин и др., 2019): строки и строфы

с неоднозначной расстановкой ударения сравниваются со строками и строфами, в словах которых ударения расставляются однозначно, и производится выбор ударения, обеспечивающего единство метрической характеристики для всего стихотворения.

Для разрешения этих ситуаций используется алгоритм расстановки ударений, определяющий метр и стопность на корпусе стихотворений А. С. Пушкина с точностью в 95,5 %, при этом основной процент погрешности дают стихотворения с отточиями: неоконченные, с обценной лексикой и т.п.

Алгоритм включает в себя следующие шаги:

1. Предварительная обработка текста: разбиение текста на строки, а также удаление знаков препинания.

2. Акцентуация на основе словаря А. А. Зализняка, в котором содержатся акцентуированные словоформы, устранение неоднозначности расстановки ударения.

3. Создание для всех строк слоговых схем путем разбиения каждого слова текста на слоги с последующим удалением пробела между словами и переводом в последовательность символов «с» и «С», обозначающих соответственно безударный и ударный слоги.

4. Извлечение параметров, необходимых для дальнейшей классификации текстов, таких как общее число слогов R , число ударных слогов k , междуакцентное расстояние (расстояние между соседними ударными слогами) r , анакруза $r(0)$ (число безударных слогов в начале слоговой схемы), клаузула $r(k)$ (число безударных слогов в конце слоговой схемы).

Выполнена практическая реализация и тестирование условий согласно классификации текстов по метроритмическим схемам. На рисунке 1 представлен пример работы программного модуля определения метроритмики, предоставляющего пользователю выходные данные о метрике, акцентуации, строфике, стопности.

Метроритмический анализ © ФИЦ ИВТ

Форма позволяет проводить метроритмический анализ поэтических текстов. Вставьте текст в поле **Форма вставки текста** и нажмите **Х** на кнопку **Проанализировать**. Сохраните полученные результаты, выделив требуемые характеристики и нажав на кнопку **Сохранить**. Чтобы проверить работу формы на тестовом примере, нажмите на кнопку **Пример**. В поле **Форма вставки текста** будет вставлен пример поэтического текста для анализа.

Форма вставки текста **Пример**

Мчатся тучи, выются тучи;
Невидимкою луна
Освещает снег летучий;
Мутно небо, ночь мутна.

☐ Содержит HTML-разметку

Проанализировать **Очистить все**

☐ Результаты **Сохранить**

☐ Метрика

☐ Маска акцентуации

☐ Строфика

☐ Стопность

МЧАТСЯ ТУЧИ ВЫЮТСЯ ТУЧИ
НЕВИДИМКОЮ ЛУНА
ОСВЕЩАЕТ СНЕГ ЛЕТУЧИЙ
МУТНО НЕБО НОЧЬ МУТНА

Рис. 1. Программный модуль определения метроритмики.

Представлены алгоритмы определения строфики и рифмы, как единой основы анализа фонетического уровня текста. Алгоритм нахождения строфики заключается в сопоставлении шаблонов строфик изучаемому поэтическому тексту:

1. Шаблоны строфик из справочника переводятся из буквенного представления во множество индексов рифмующихся строк (например, строфика вида *abab* переводится в множество индексов рифмующихся строк $[[0, 2], [1, 3]]$).

2. Фиксируется информация о том, какие из строк данного поэтического текста

имеют мужские/женские клаузулы (чтобы различать, например, случаи *abab* и *baba*).

3. Из множества строк с мужской клаузулой образуется подмножество всевозможных пар строк, что сделано с целью проверки, удовлетворяет ли данная пара строк правилам образования рифмы.

4. Для каждого шаблона строфики ищется точность определения.

5. Аналогичным образом шаги 3 и 4 выполняются для строк с женской клаузулой.

Автоматическое определение характеристик, связанных со стопностью, требует нахождения рифмующихся строк, соответственно, алгоритм поиска рифм основан на соображениях возможности их образования: строки рифмуются, если у последних слов в строке одинаковая позиция ударного слога и фонетически совпадают окончания. С использованием списка пар буквосочетаний, отражающих звуки рифмующихся стиховых окончаний из литературы XVIII —XIX веков, разработан алгоритм определения рифмы, который состоит из следующих последовательных шагов:

1. Разбиение текста на строфы.

2. Нумерация строк и извлечение последнего слова из каждой строчки строфы.

3. Определение акцентуации для каждого слова, поиск множеств слов с одинаковым вариантом акцентуации.

4. Поиск множеств слов, окончания которых рифмуются (фонетически совпадают).

5. Поиск пересечения множеств из п. 3 и 4 — полученные рифмующиеся строки.

6. Представление вида рифм в буквенном виде: каждому множеству рифмованных строк присваивается буква латинского алфавита, причем мужской — строчная буква, женской — заглавная буква. На основе полученных обозначений составляется буквенная последовательность строк в строфе.

В ходе тестирования алгоритма выявлено, что часть ошибок в определении типа строфики связана с неполнотой множества фонетически рифмующихся окончаний, поэтому алгоритм претерпел некоторые модификации для повышения точности.

Представлены подходы к созданию метрических справочников, в основе которых лежит разработка и реализация алгоритма анализа метра, стопности и рифмы, описанного выше. Создание метрических справочников, соответственно, включает в себя модификации данного алгоритма для снятия проблем неоднозначной акцентуации, омографов и клитик. Надо отметить, что для анализа структурного уровня русскоязычных поэтических текстов не существует практически реализованных систем, что, безусловно, подчеркивает пионерный характер настоящей работы.

Программа по определению метроритмических характеристик предоставляет следующие данные о тексте, составляющие основу метрических справочников:

1. Количество строк, без учета пустых.

2. Метрика стихотворения.

3. Стопность.

4. Рифмовка строфики.

5. Количество мужских окончаний последних слов в стихотворных строках.

6. Количество женских окончаний последних слов в стихотворных строках.

7. Количество дактилических и др. окончаний последних слов в стихотворных строках.

8. Количество нерифмованных мужских окончаний.

9. Количество нерифмованных женских окончаний.

10. Количество нерифмованных дактилических и других окончаний.

11. Количество строк без конечных слов.

Выходные данные дают информацию для заполнения таблиц, аналогичных таблицам I, II, VII, X, XIII, XIV, XV в Метрическом справочнике, а также приведенным в нем индексам I, II, IV. Пример работы программного модуля представлен на рисунке 2.

Метроритмические справочники				
Не защищено poem.ict.nsc.ru/system/mrrhyme_dict/2				
Система комплексного анализа поэтических текстов			Подразделы ▾	Здравствуйте, Гость ▾
Назад				
Метроритмический справочник автора Алексей Константинович Толстой				
№	Произведение	Маска акцентуации	Рифма	Метрика
1	Алеша Попович	СсСсСсСсСс СсСсСсСс СсСсСсСс СсСсСсСс СсСсСсСсСс	свободная строфика	хорей
2	Алхимик	сСсСсСсСс сСсСсСсСс сСсСсСсСс сСсСсСсСсСс	свободная строфика	ямб
3	[А.М.Жемчужникову] "Вхожу в твой кабинет..."	сССсСсСс сСсСсСсСс ССсСсСсСс сСсСсСсСс сСсСсСсСс сСсСсСсСс сСсСсСсСс	толстой3	ямб
4	[А.М.Жемчужникову] "Мы тебя субботним днем..."	СсСсСсСс СсСсСсСс СсСсСсСс СсСсСсСс СсСсСсСс СсСсСсСс СсСсСсСс СсСсСсСс	bbadda	хорей
5	[А.М. и Н.М.Жемчужниковым]	СсСсСсСсСсСс СсСсСсСс СсСсСсСсСсСс СсСсСсСс	толстой2	дактиль
6	* Аминь, глаголю вам, - в восторге рек Маркевич...	сСсСсСсСсСсСсСс сСсСсСсСсСсСсСс СсСсСсСсСсСсСс СсСсСсСсСсСсСсСс сСсСсСсСсСсСсСсСс СсСсСсСсСсСсСс	aabccb	ямб

Рис. 2. Пример работы программного модуля.

В четвертой главе исследованы принципы и разработаны алгоритмы автоматизации процесса создания метрических справочников и конкордансов. Принципы составления конкордансов и метрических справочников опираются на усовершенствованный метод акцентуации слов поэтического текста, учитывающий, в частности, его ритмическую структуру, позволяющий непосредственно повысить точность определения метроритмических характеристик поэтических текстов и значительно улучшающий качество автоматического разрешения неоднозначности омографов, что, в свою очередь, дает возможность генерации семантически верных справочников.

Обозначены проблемы и показаны методы автоматизированного выделения словосочетаний, отличающиеся по обучению (необучаемые, самообучаемые и обучаемые), по математическому аппарату распознавания (статистические, структурные и нейросетевые), по лингвистическим ресурсам (использующие или не использующие лингвистические ресурсы, словари, онтологии, тезаурусы, корпуса текстов). Для задач автоматизации комплексного анализа русских поэтических текстов, предназначенных для составления словарей языка поэта (которые в идеале должны включать не только слова, но и словосочетания, характеризующие поэтическую речь данного автора), принципиально выделение из текста всех словосочетаний, а также выявление среди них эквивалентных, отличающихся только грамматической формой.

Представлены принципы составления конкордансов, справочников и словарей языка поэтов. Современный подход к построению конкордансов таков: словарная статья представлена основным заголовочным словом — лексема, приведенная к лемме (т.е. снята неоднозначность в случае омонимов, омографов и полисемии), внутри которой также разделяются все возможные омоформы; для разделения омоформ между собой они могут быть сопровождаемы грамматической информацией; каждая словарная статья (ее заголовочное слово) может быть дополнена кратким толкованием для учета омонимии и полисемии. В общем случае словарная статья в конкордансе может быть представлена некоторой *n*-граммой, однако в дальнейшем мы будем придерживаться частного случая специфичного для поэзии, в котором производится конкорданция только отдельных слов — униграмм. Каждая словарная статья сопровождается, как правило, следующей информацией: частота употребления; примеры употребления (контекст); ссылки на контексты; также при необходимости могут быть включены грамматическая информация и краткое толкование.

Основной трудностью автоматизации построения конкордансов является разрешение неоднозначных графем, то есть определение их лексических и грамматических характеристик. Для решения данной задачи нами составлена необходимая, при составлении словарей поэтического языка и конкордансов, классификация различных случаев неоднозначности, основанных на совпадении и несовпадении ударений и, в свою очередь, постоянных и непостоянных грамматических признаков.

Поскольку конкорданс предоставляет инструмент для изучения лексического уровня произведения, при его составлении необходимо делать упор на семантику слов, поэтому графемы должны быть разведены в различные словарные статьи. Для этого необходимо снять неоднозначность в общеизвестных случаях:

1. Омонимы — слова различные по значению, но совпадающие по написанию и звучанию.

1.1. Полные омонимы — совпадает вся словоизменительная парадигма.

1.2. Частичные омонимы — совпадают не все словоформы.

2. Омоформы (грамматические омонимы) — разные слова, совпадающие в отдельных грамматических формах.

2.1. Внутрилексемные омографы.

2.2. Межлексемные омографы.

3. Омографы (графические омонимы) — слова, совпадающие по написанию, но различные по звучанию и значению.

3.1. Внутрилексемные омографы.

3.2. Межлексемные омографы.

4. Полисемия — наличие у слова двух и более значений.

Неоднозначность акцентуации снимается алгоритмом, работающим методом «по аналогии» с учетом единства метрической характеристики. Предложенный нами алгоритм обращается к словарям для обнаружения ситуации омонимии и полисемии, таким образом, разведение этих понятий базируется на основе экспертной информации, изложенной в словаре, дальнейшее снятие неоднозначности производится пользователем экспертом вручную.

Алгоритм автоматического построения конкордансов с фиксацией неоднозначности и снятием неоднозначности акцентуирования следующий:

1. Для каждого текста:

1.1. Текст подается на вход акцентуатору. На выходе имеем графемы с проставленными ударениями.

1.2. Для каждой графемы в тексте:

1.2.1. Графема подается на вход алгоритму морфологического анализа.

Выход: варианты морфологического разбора для данной графемы.

1.2.2. Объединяем в отдельные множества те варианты, что имеют одинаковую лемму.

1.2.3. Для каждого множества:

1.2.3.1. Находим все возможные значения леммы в словаре.

1.2.3.2. Разбиваем множество на подмножества, исходя из значений леммы: в каждое подмножество попадают разборы с совпавшей для этой леммы словоизменительной парадигмой (написание и морфологические признаки), указанной в словаре.

1.2.3.3. Оставляем только те множества, ударения в которых совпали с ударением, определенным акцентуатором для анализируемой графемы.

1.2.4. Сохраняем полученную на предыдущих шагах информацию для текущей графемы.

1.2.5. Инкрементируем счетчик вхождений лексемы, определенной для данной графемы.

1.2.6. Сохраняем контекст графемы.

1.2.7. Сохраняем ссылку на контекст.

1.3. Возвращаемся к шагу 1.2, пока есть графемы. Иначе — шаг 2.

2. Возвращаемся к шагу 1, пока есть тексты. Иначе — конец алгоритма.

Об алгоритме акцентуации, используемом на шаге 1.1, сказано в главе 3; в качестве морфологического анализатора (шаг 1.2.1) использована библиотека *rumorphy2*; на шаге 1.2.3.1 алгоритм построения конкорданса обращается к Викисловарю (который включает большой объем данных и представляет собой своего рода компиляцию множества авторитетных академических словарей).

На выходе алгоритма получаем конкорданс, представленный в виде файла в формате json, пример — на рисунке 3.

```
01. {
02.   <лексема>: {
03.     "count"      : <количество вхождений в корпусе>,
04.     "graphemes" : {
05.       <графема+ударение>: {
06.         "morph": [<список вариантов морф.разбора>],
07.         "context": [<список контекстов>],
08.         "ref": [<список ссылок на контексты>]
09.       }
10.     }
11.   }
12. }
```

Рис. 3. Структура файла-конкорданса.

Объект верхнего уровня — сам конкорданс, ключами которого являются лексемы (в лемматизированном виде). Значение каждой лексемы — объект второго уровня вложенности. У этого объекта есть два ключа: первый *count* хранит количество вхождений лексемы в корпусе, второй *graphemes* предназначен для хранения графем, принадлежащих к данной лексеме, и информации о них. Значение ключа *graphemes* — объект третьего уровня вложенности. Этот объект хранит множество уникальных ключей, представленных графемами и ударениями в них (уникальность одинаково пишущихся графем обеспечивается за счет указания информации об ударении). Каждый такой ключ содержит объект четвертого уровня вложенности. Этот объект имеет три ключа: *morph* — хранит список вариантов морфологического разбора в виде строк, *context* — хранит список контекстов употребления графемы, *ref* — хранит список ссылок на контексты.

Таким образом, реализован алгоритм автоматического построения конкордансов с фиксацией и снятием неоднозначности акцентуирования, что обеспечивает семантическую точность составляемых словарей.

Пятая глава посвящена автоматизации исследований категорий жанра и стиля поэтических текстов.

Представлены подходы к автоматизированному определению жанровых типов и стилистических характеристик. Метод опорных векторов позволяет получить хорошие результаты при определении стилей, и удовлетворительные — при определении жанров, однако далее используемый подход расширяется: при построении характеристического вектора

используемых в стихотворении лексем учитывается количество их вхождений, также получены результаты экспериментов с характеристическими векторами биграмм и триграмм.

Обосновано построение обучающей выборки, при этом наиболее эффективным подходом к автоматизации определения жанровых типов и стилистических характеристик является использование алгоритмов с обучением. При формировании обучающей выборки было решено остановиться на лицейской лирике А. С. Пушкина (1814 — 1817 гг.), поскольку в ней наблюдается использование наиболее строгих жанровых форм, стилистическое единство, а также следование правилам грамматики своего времени. Выделяются канонические и неканонические жанры, по одной оси — жанровые типы в порядке возрастания «возвышенности» (ода, элегия, идиллия, послание и т.д.), по другой оси — традиционные стили, так обосновывается «двумерный» (жанрово-стилевой) классификатор. На этом материале просматривается очевидная корреляция между жанровыми и стилистическими характеристиками текстов, стиль характеризуется лексемами в гораздо большей степени, чем жанр, хотя, применительно к описываемому эксперименту в частности и к глобальным литературным категориям и процессам вообще, количество жанров существенно больше, чем количество стилей. В таблице 1 приведен результат эксперимента на обучающей выборке.

Табл. 1. Статистика по жанрово-стилевому соответствию.

	Высокий	Средний	Низкий
Ода	4	-	-
Притча	1	1	-
Мадригал	4	-	-
Послание	-	55	5
Идиллия	-	2	-
Элегия	-	37	-
Романс	-	1	-
Баллада	-	3	-
Эпиграмма	-	-	18
Анекдот	-	-	1

Представлено обсуждение возможности создания словаря стилистически дифференцированных лексем. Вхождение в текст отдельных лексем не может служить достаточно надежным критерием отнесения текста к определенному стилистическому типу, поскольку большинство лексем имеет полисемантическую окраску. Наиболее целесообразно определять стилистические и жанровые характеристики поэтических текстов на основании вхождения в них совокупности лексем (включая n -граммы), определяемых обучающей выборкой.

Описан численный эксперимент, для которого использовалась выборка лицейской лирики А. С. Пушкина из 121 стихотворения, размеченных экспертом по жанрам и стилям. При обучении создан словарь нормализованных форм всех уникальных слов, встречающихся в текстах; отдельно составлен словарь имен собственных, которые удалялись из словаря всех слов. Каждый текст кодировался последовательностью цифр, соответствующей словарю в порядке слов: 0 ставился, если слова нет в тексте, 1 — если слово встречается 1 раз, 2 — если 2 и т.д. Также были собраны словари n -грамм ($n=2, 3$), которые не содержали имён собственных, причем n -граммы были не упорядоченными внутри себя, поскольку в поэзии очень часто встречается альтернативный порядок слов.

Использованные приемы ансамблирования: два варианта взвешенного голосования с использованием нескольких классификаторов (hard (заключение большинства) и soft (максимизация отнесения); бустинг (добавление алгоритма для компенсации ошибок): AdaBoost; Gradient boosting; SVM, усиленный AdaBoost; стекинг (преобразование исходного пространства признаков задачи в новое пространство, точками которого являются предсказания

базовых алгоритмов). В качестве мета-алгоритма была взята логистическая регрессия над SVM, градиентным бустингом, многослойным персептроном и голосованиями. Для решения проблемы миноритарных классов были применены случайное дублирование элементов миноритарных классов, а также стратегия SMOTE, которая основана на идее генерации некоторого количества искусственных примеров, «похожих» на имеющиеся в миноритарном классе, но при этом не дублирующих их.

Для создания новой записи вычисляют разность $d = X_b - X_a$, где X_a, X_b — векторы признаков «соседних» примеров a и b из миноритарного класса, которые находят, используя алгоритм ближайшего соседа, далее из d путем умножения каждого его элемента на случайное число в интервале $(0, 1)$ получают $\hat{d}$. Вектор признаков нового примера вычисляется путем сложения X_a и $\hat{d}$. Алгоритм SMOTE позволяет задавать количество записей, которое необходимо искусственно сгенерировать. Степень сходства примеров a и b можно регулировать путем изменения значения k (числа ближайших соседей). Программный модуль для классификации поэтических текстов реализован на языке Python с использованием библиотек *sklearn* (реализация алгоритмов, их композиций и кросс-валидации), *imblearn* (реализация SMOTE), *xgboost* (наиболее эффективная реализация градиентного бустинга) и *rumorphy2* для приведения слов к нормализованному виду, а также для отсекаания имен собственных. В таблицах 2 и 3 приведены результаты эксперимента с триграммами слов.

Табл. 2. Триграммы + SMOTE для определения стиля.

Классификатор	Среднее	Max	Min
SVM AdaBoost	0.83	0.98	0.88
XGBoost	0.90	0.94	0.87
Многослойный персептрон	0.95	0.99	0.93
Голосование, hard	0.93	0.98	0.89
Голосование, soft	0.91	0.98	0.88
Стекинг	0.94	0.98	0.89

Табл. 3. Триграммы + случайное дублирование миноритарных классов для определения жанра.

Классификатор	Среднее	Max	Min
SVM AdaBoost	0.95	1.00	0.86
XGBoost	0.94	1.00	0.84
Многослойный персептрон	0.97	0.99	0.95
Голосование, hard	0.96	1.00	0.91
Голосование, soft	0.96	1.00	0.91
Стекинг	0.96	1.00	0.88

На основе проведенных экспериментов можно сделать следующие выводы:

- 1) Стекинг не всегда даёт наилучшее решение;
- 2) При увеличении контекста признаков (от одного слова к би- и триграммам) XGBoost становится более точным, чем многослойный персептрон;
- 3) Увеличение ширины контекста приводит к улучшению качества, но, только до определённого момента. Применение популярной концепции *word2vec* дало очень слабый результат (0.83-0.85), и при этом время подсчёта увеличилось в несколько раз;
- 4) Даже с помощью простых классификаторов на основе лексических признаков или n -грамм можно получить хороший результат;

5) Исходя из критерия максимизации минимальной точности, следует использовать многослойный персептрон, а в качестве лексических характеристик стихотворений — триграммы.

Представлено обсуждение извлечения лексических и метроритмических признаков, характерных для жанра и стиля и их комбинаций, в процессе автоматизированной обработки текстов на русском языке. Компонент семантического анализа включает в себя извлечение словосочетаний и характеристик слов, связанных с синонимией: эти процессы взаимозависимы. Определение жанра, стиля и других характеристик прагматического уровня текста выполняется с использованием машинного обучения, что позволяет построить рекомендательную систему на основе интеллектуального анализа извлеченных данных. Обученный классификатор позволяет выделить ключевые для определения жанра и стиля лексические признаки исходя из весовых коэффициентов классификатора в совокупности с его качеством.

Извлечение наиболее важных признаков для классификации состоит из анализа весовых коэффициентов обученного классификатора и оценок точности и полноты для конкретных случаев. Инструментарий: библиотеки языка Python: *scikit-learn* (в которой реализованы алгоритмы классификации, а также методы их комбинирования) и *ELI5* (позволяющая установить соответствие между компонентами вектора признаков с конкретными признаками). В таблице 4 приведены выходные данные, полученные из *ELI5*, — эксперимент на корпусе текстов (лирика А. С. Пушкина лицейского периода, лирика А. С. Пушкина 1818 — 1825 годов и вся лирика К.Н. Батюшкова). Для каждого стихотворения извлекаются несколько признаков, включая признаки TF-IDF матрицы: вхождение слов из стихотворения в словарь русского языка XVIII в., метроритмические признаки (тип рифмы, размер, строфа, количество мужских и женских окончаний, год написания стиха).

Табл. 4. Описание эксперимента на корпусах текстов.

Низкий стиль Признаки с наибольшим весом		Средний стиль Признаки с наибольшим весом		Высокий стиль Признаки с наибольшим весом	
Вес	Признак	Вес	Признак	Вес	Признак
+ 1.991	ты	+ 1.702	он	+ 1.522	из словаря русского языка XVIII в.
+ 1.925	которого	+ 0.702	друг	+ 1.518	роковой
10174 признака с положительным весом		11710 признаков с положительным весом		15007 признаков с положительным весом	
25605 признаков с отрицательным весом		24069 признаков с отрицательным весом		20772 признака с отрицательным весом	
– 1.686	вас	– 1.379	<BIAS>	– 1.764	которого
– 10.453	<BIAS>			– 2.171	чего
				– 5.013	<BIAS>

Столбцы таблицы соответствуют целевым классам; в каждом столбце приведены характеристики и их веса; байесовский признак пересечения показан как <BIAS>; положительные/отрицательные веса выделены двумя цветами. Можно рассмотреть признаки и их веса, так как используется модель «мешок слов», либо вектор n -грамм и классификатор (таким образом, имеется прямое соответствие между отдельными словами или n -граммами и коэффициентами классификатора). Для решения проблемы разности весов множеств, принадлежащих к тем или иным классам, использован алгоритм SMOTE, а также случайное дублирование примеров класса меньшей мощности. После извлечения признаков логистическая регрессия была обучена, и признаки, оказавшиеся наиболее важными для принятия решения, использованы для обучения модели многослойного персептрона. Получена средняя F_1 -мера 95% по результатам перекрёстной проверки на трёх разбиениях для каждого автора, что

отражено в таблице 5, однако следует заметить, что некоторые классы определяются хуже, так как представлены слишком малым количеством примеров.

Табл. 5. Эксперимент с определением жанра/стиля на многослойном персептроне с признаками, которые оказались наилучшими для логистической регрессии.

	Средняя F_1 -мера	Максимум F_1 -меры	Минимум F_1 -меры
А. С. Пушкин	0.93	0.95	0.92
К. Н. Батюшков	0.91	0.92	0.89

Для уменьшения размерности вектора признаков использованы: усечённый вариант SVD (singular value decomposition, сингулярное разложение) и SVD как часть PCA (principal component analysis, метод главных компонент), который используется для разложения многообразного набора данных в набор последовательных ортогональных компонент, объясняющих максимальный объём вариативности, что позволяет проецировать данные в сингулярное пространство с масштабированием каждой компоненты по области значений, — такой процесс полезен в моделях последовательной обработки для уверенных предположений о подобности объектов. Усечённый SVD реализует вариант разложения сингулярных значений, считая только k наибольших сингулярных значений по заданному параметру k . При применении SVD к матрицам терминов-документов, например, матрице TF-IDF, получается преобразование, известное как латентный семантический анализ — LSA (latent semantic analysis), так как оно преобразует матрицы такого рода в семантическое пространство низкой размерности. В частности, LSA устойчиво к проблемам синонимии и полисемии (оба термина подразумевают многозначность слов), которые в случае матриц терминов-документов приводят к их чрезмерной разреженности и плохим результатам некоторых метрик, что недопустимо в рамках задачи классификации текстов.

Приведены этапы решения задачи объяснения прогнозов классификатора: построение алгоритма классификации текстов, разработка способов векторного представления текстовых объектов, выбор конкретной модели, подбор параметров алгоритма, зависящий от характеристик решаемой задачи.

Формальное определение задачи классификации следующее.

Пусть множество $D = \{d_i\}_{i=1}^n$ — выборка объектов, каждый элемент которой характеризуется вектором признаков размерности n' . Результатом классификации объекта d_i является некоторое значение из ограниченного множества $T = \{1, \dots, m\}$. Тогда основная цель задачи распознавания заключается в поиске алгоритма, который бы по вектору признаков однозначно определял итоговое значение из множества T или выдавал вектор оценок принадлежности объекта каждому из классов. При этом на начальном этапе существует некоторое подмножество объектов с уже известным результирующим классом, такие объекты составляют обучающую выборку. При проекции описанного выше определения на задачу классификации текстов по стилям или жанрам, получается, что d_i — это поэтический текст, характеризующийся набором признаков (пока неизвестно каких), на основе которых алгоритм классификации определяет принадлежность текста к одному стилю или жанру, и обозначенными уникальными значениями из $\{1, \dots, m_s\}$ и $\{1, \dots, m_g\}$.

Объяснение прогнозов классификатора — это представление текстовых артефактов, которые обеспечивают качественное понимание взаимосвязи между словом в документе и предсказанием модели: для дальнейшего отображения объяснений классификатора использован алгоритм LIME (Local Interpretable Model-agnostic Explanations), позволяющий выявить такую информацию. Важно различать используемые для классификации признаки и интерпретируемые представления данных, которые должны использовать объяснение, понятное для пользователей, независимо от фактических характеристик, используемых моделью. Возможным интерпретируемым представлением для классификации текста является

двоичный вектор, указывающий наличие или отсутствие слова, хотя классификатор может использовать более сложные признаки текста.

Пусть $x \in R^k$ — вектор признаков некоторого объекта размерности k , а $x' \in \{0, 1\}^{k'}$ — бинарный вектор объекта, необходимый для интерпретации. Через G обозначим класс потенциально интерпретируемых моделей (к таким моделям относятся, например, линейные модели или деревья решений), а $g \in G$ — конкретная модель, которая может быть легко продемонстрирована пользователю в виде текстового артефакта. Областью действия модели g является $\{0, 1\}^{k'}$, то есть g действует над отсутствием/присутствием интерпретируемых компонент. Ввиду того, что не все $g \in G$ просты для интерпретации, необходимо ввести $\Omega(g)$ — меру сложности объяснения модели g . Например, для деревьев решений мерой сложности будет являться глубина дерева, а для линейной модели — число ненулевых весов.

Рассмотрим $f: R^k \rightarrow R$ — объясняемую модель, где $f(x)$ представляет собой вероятность (или бинарный идентификатор) того, что объект x принадлежит к тому или иному классу. Для нескольких классов объяснение происходит отдельно, поэтому $f(x)$ является предсказанием определенного класса. Введем $\pi_x(z)$ — меру близости между объектами x и z , необходимую для определения окрестности объекта x . Наконец, $\mathcal{L}(f, g, \pi_x)$ — мера того, насколько неверная модель g приближается к модели f в окрестности, определяемой π_x . В итоге для достижения интерпретируемости необходимо минимизировать функцию $\mathcal{L}(f, g, \pi_x)$, при этом $\Omega(g)$ должна быть достаточной мала. Получаем следующую формулу, дающую объяснение прогноза:

$$\varepsilon(x) = \operatorname{argmin}_{g \in G} \mathcal{L}(f, g, \pi_x) + \Omega(g).$$

Пусть G — класс линейных моделей, то есть $g(z') = w_g * z'$. В качестве меры близости используется функция $\pi_x(z) = \exp(-\frac{D(x,z)^2}{\sigma^2})$ — экспоненциальное ядро, определенное над некоторой функцией расстояния D с шириной σ . Для текстов в качестве D используется косинусоидальное сходство — отношение скалярного произведения векторов и произведения их норм. Таким образом, функция $\mathcal{L}(f, g, \pi_x)$ приобретает следующий вид:

$$\mathcal{L}(f, g, \pi_x) = \sum_{z, z' \in Z} \pi_x(z) * (f(x) - g(z'))^2.$$

В итоге пользователь не только видит результаты классификации, но и получает предположительное пояснение, почему те или иные выводы были сделаны: предоставляется информация о результирующих прогнозах классификатора в виде таблицы. Кроме того, доступна информация об объяснении сделанных прогнозов для каждого текста, в этом случае объяснение представляет собой список слов с относительными весами, такой результат выдается в виде изображения, на котором с разной интенсивностью, зависящей от веса, слова подсвечены цветом.

Таким образом, разработанный программный модуль существенно облегчает работу эксперта при определении стилей и жанров поэтических текстов благодаря рекомендованным системой результатам. Помимо этого, достигается минимизация времени обучения взаимодействия пользователя с системой, которая приводит к увеличению скорости и качеству классификации. Следует отметить, что данное решение не привязано к каким-то конкретным категориям классификации, что делает её универсальной.

В **шестой главе** представлены результаты, связанные с исследованием зависимости верхних уровней структуры поэтических текстов от характеристик нижних уровней. Задача автоматизированного определения характеристик поэтических текстов, относящихся к верхнему уровню, прежде всего, жанра и стиля, наиболее эффективно решается методами машинного обучения, которые позволяют не только довести точность до показателей в

пределах от 95 до 100 %, но и использовать полученные результаты классификации в решении задач определения авторского стиля.

У ансамблевых методов, обеспечивающих взаимодействие различных моделей машинного обучения, есть существенный недостаток: для получения предсказания нужно дожидаться, пока отработают все модели, поэтому предложен подход, призванный с допустимой потерей в качестве значительно ускорить работу набора моделей. В задаче классификации поэтических текстов по жанру и стилю нет ограничений по времени, однако, для стабильной работы интерфейса к этому инструменту должно быть априорно заданное соглашение о времени ответа сервера, что соответствует стандартам SLA (Service Level Agreement — соглашение об уровне обслуживания). Таким образом, с одной стороны, гарантируется ответ за комфортное для пользователя время и корректную обработку ответа интерфейсом, с другой, в набор можно вводить более сложные модели, при этом не уменьшая общее время ответа для каждого пользователя.

Для сравнения были взяты две простые эвристики:

1) Стандартная очередь FIFO: запрос по умолчанию к набору моделей идет к первой свободной из них, если свободных моделей несколько — модель выбирается случайным образом;

2) Round-robin — алгоритм распределения нагрузки по круговому циклу: каждый последующий запрос к набору серверов идет на следующий из них в априорно определенной очереди. Как только очередь заканчивается, запрос снова идет на первый в очереди сервер и так далее. Все эксперименты были выполнены на наборе, содержащем три базовые модели: логистическую регрессию и реализации многослойного персептрона из *scikit learn* и классификатора XGBoost из отдельного модуля.

Подход к сравнению моделей основан на оригинальной методике И. С. Пастушкова (В. Б. Барахнин и др., 2021), использующей различные алгоритмы проведения экономических аукционов: предложен прием, позволяющий значительно ускорить работу набора моделей — получение предсказаний с максимально возможной за фиксированное время точностью. Данную задачу можно рассматривать как одностадийную задачу с директивными сроками на нескольких машинах, что означает поток задач, которые должны быть обработаны на одной из машин, и так как каждая работа выполняется один раз, мы можем пренебречь простоями между стадиями. Целевая функция для таких задач:

$$L_{\max} = \max_{i=1,\dots,n}(c_i - c'_i) \rightarrow \min,$$

где c_i — время, затраченное на i -ю работу, c'_i — общий директивный срок выполнения i -работы согласно стандарту SLA. Целевая функция означает, что минимизируются нарушения SLA для работ в среднем. Задачи с директивными сроками решаются построением матрицы времён выполнения работ и выбором лучшего варианта, однако мы не обладаем априорным знанием о времени выполнения и помимо этого мы должны учитывать качество, которое используется как приоритет машины в рамках теории расписаний: если набор машин состоит из машин со сходным качеством, то мы всегда получаем лучший результат на доступных машинах. Так, если в наборе три машины с качеством 90, 91, 92% мы действительно получим результат от машины с наилучшим качеством, но при условии, что нет других запросов к кластеру и эта машина свободна. Но в таком случае, нет смысла в остальных машинах в наборе. При такой постановке задачи аукционные эвристики решают проблему при довольно высокой нагрузке кластера и позволяют соблюдать SLA, что для нашей задачи является профитом.

Рассмотрены три модели аукционов: английский аукцион (повышение ставки); аукцион Викри (побеждает участник, предложивший максимальную ставку, но покупка осуществляется по второй максимальной ставке); голландский аукцион (уменьшение ставки). Во всех случаях в качестве ставки использовалась уверенность в предсказании (качество ответа каждой модели), а также устанавливался временной параметр, по истечении которого предсказание признается окончательным. Тестирование, проведенное как на корпусе новостных сообщений (на набор данных 20 групп новостей, содержащем около 20 000 текстов), так и на выборке лицейской

лирики А. С. Пушкина, показало, что модели аукциона Викри и голландского аукциона при сравнении с базисным методом дают выигрыш по времени с аналогичным качеством, а английский аукцион имеет преимущество по времени перед циклическим алгоритмом со сравнимым качеством, выигрывая у стандартной очереди в качестве при сравнимом времени.

Таким образом, проблемы несбалансированности классов и малого объема корпуса текстов, характерные для классификации поэтических текстов, успешно решаются применением различных методов генерации данных.

Проведён эксперимент на корпусе ранней лирики А. С. Пушкина для более корректного сравнения. Таблица 6 содержит данные экспериментов: полученные результаты и их сравнение с методами ансамблирования и балансировки позволяют сделать вывод о том, что предложенный подход без специальных модификаций может быть использован для задачи классификации поэтических текстов и полезен при построении многомодельных систем классификации русских поэтических текстов по признакам, относящимся к верхнему уровню, прежде всего, по жанру и стилю, и включён в интерфейс системы.

Табл. 6. Данные экспериментов на корпусе поэтических текстов.

Метод	50th	80th	90th	95th	Стандартное отклонение
Baseline	0.76	0.79	0.8	0.8	0.03
First free	0.75	0.83	0.87	0.87	0.09
Round-robin	0.73	0.83	0.88	0.88	0.12
Английский аукцион	0.76	0.88	0.87	0.87	0.09
Аукцион Викри	0.71	0.81	0.85	0.85	0.11
Голландский аукцион	0.7	0.79	0.83	0.83	0.1

Представлено определение признаков авторского стиля стихотворений А. С. Пушкина методами машинного обучения. Современная стилеметрия в большей мере связана с анализом печатных текстов, представленных в электронном виде, что обусловлено активной цифровизацией общества, поэтому необходимость решать значительное количество задач стилеметрии привела к расширению использования компьютерных методов. Стилеметрия в контексте атрибуции авторства предполагает выявление особенностей авторского стиля, поддающихся количественному описанию, при этом объяснение решения классификаторов дает возможность с большей определенностью говорить об особенностях авторского стиля. Экспериментальной задачей в таком контексте является определение признаков авторского стиля А. С. Пушкина, а также поэтов пушкинской эпохи, с использованием методов машинного обучения. Так как эти методы требуют данных для сопоставления и выявления признаков, характеризующих авторский стиль, задача сформулирована как задача бинарной классификации, в которой выделялись два класса: стихотворения А. С. Пушкина, и стихотворения ряда других поэтов пушкинской эпохи. В качестве данных решено было использовать исключительно стихотворения, которые как данные для классификации обладают определенной спецификой: это небольшие произведения, от использования методов сжатия было решено отказаться, но признаки, описывающие частотность элементов, составляют основу данной работы. Для оценки влияния размера стихотворений на качество классификации был построен дополнительный набор данных, в который вошли только стихотворения, состоящие не менее чем из 16 строк, в предположении, что такой набор данных покажет лучшую точность классификации; описание этого набора из 1162 стихотворений представлено в таблице 7.

Табл. 7. Набор данных стихотворений поэтов пушкинской эпохи.

Поэт	Количество стихотворений		Доля в наборе данных	
	Исходная выборка	Не менее 16 строк	Исходная выборка	Не менее 16 строк
А. С. Пушкин	685	322	0.3467	0.277
В. А. Жуковский	379	261	0.6533	0.723
П. А. Вяземский	268	190		
Е. А. Баратынский	197	106		
А. А. Дельвиг	194	118		
К. Н. Батюшков	109	88		
Д. В. Давыдов	77	31		
Н. И. Гнедич	67	46		

Выделяются следующие группы признаков, которые в наибольшей мере характеризуют авторский стиль:

- распределение по частям речи и отношениям (синтаксический уровень),
- частоты знаков препинания (пунктуационный уровень),
- слова и их n -граммы (лексический уровень),
- служебные слова (лексический уровень),
- буквы и другие символы, а также их n -граммы (фонетический уровень),
- метроритмические признаки (фонетический уровень).

Алгоритмы разработаны и реализованы И. В. Григорьевой (В. Б. Барахнин и др., 2022); для описания структуры предложений использовались универсальные зависимости (структура для графического представления грамматики), извлекаемые UDpipe2; для получения матрицы «объекты-признаки» использовалась модель текста TF-IDF; для классификации применялись ансамблевые методы на основе решающих деревьев: extra-trees classifier (ET), random forest classifier (RF), AdaBoost classifier (AB), gradient boosting for classification (GB), CatBoost classifier (CB); multi-layer perceptron classifier (MLP); а также support vector classification (SVC) и logistic regression classifier (RF). На первом этапе классификация по группам признаков выполнялась отдельно по каждой группе, после чего давалось заключение об ее эффективности группы. На втором этапе наиболее эффективные группы признаков объединялись, и классификация проводилась по нескольким группам признаков. Задачей второго этапа было построение наиболее точной классификации, а также выявление отдельных признаков, в наибольшей мере определяющих авторский стиль. Все оценки получены как среднее для кросс-валидации по 5 блокам со стратификацией по классам.

Сама по себе классификация не может ответить на вопрос, какие слова характерны или не характерны для творчества А. С. Пушкина, поэтому для построения объяснения были использованы метод Шепли и его реализация в виде пакета SHapley Additive exPlanations (SHAP). Объяснение строилось на основе обученного классификатора CatBoost, который продемонстрировал меньшую точность по сравнению с нейросетями (AUC ROC составил 0.8072), но эта точность оказалась наиболее высокой среди всех примененных нами ансамблевых методов на основе решающих деревьев, кроме того, пакет SHAP позволяет построить объяснение для всех тестовых примеров только для этой группы методов. Чтобы получить представление о том, какие признаки наиболее важны для построенной модели, были построены значения SHAP для каждого признака каждого примера из исходного набора стихотворений, признаки отсортированы по убыванию величин SHAP, которые характеризуют важность слов-признаков. Также была построена диаграмма, описывающая важность признаков, для классификации по 2-, 3- и 4-граммам символов с использованием метода Шепли, которая показывает, в частности, что для стихотворений Пушкина не характерно использование восклицательного знака как в конце строки так и в середине, но весьма

характерно использование точки и многоточия в конце предложения и в конце строки, а также тире в конце строки; использование слов оканчивающихся на *-ый*, *-ные* и строки на *-ый*, что коррелируется с результатом, установленным при классификации по словам, утверждающим, что Пушкин более других поэтов имел склонность к использованию прилагательных.

После оценки разных групп признаков строились различные сочетания групп, по которым проводилась классификация: лучшие результаты дали нейросети, поэтому результаты приводятся только для этой модели. Результаты кросс-валидации представлены в таблице 8. Сочетание параметров позволяет получить лучший результат, чем по любой отдельной группе, но необходимо отметить, что улучшение характеристик итоговой модели в сравнении с классификацией по символам и их *n*-граммам довольно небольшое. Группа букв и их *n*-грамм включалась в итоговый набор в двух вариантах: 2- и 3-граммы, а также 2-, 3- и 4-граммы. Хотя второй вариант дает немного большую точность, он требует значительно больших вычислительных ресурсов. Во всех случаях имеет место большее значение полноты (порядка 0.9) и меньшее значение точности. Для набора данных со стихотворениями от 16 строк значительного увеличения точности получить не удалось, максимальная AUC ROC на этом наборе составила 0.9240. В результате проведенного исследования была построена нейросеть, которая описывает стилистические особенности А.С. Пушкина.

Табл. 8. Результаты классификаций по группам признаков для основного набора данных.

Группы признаков	AUC ROC	Balanced accuracy	F_1
слова, отношения, 2-3-граммы букв, метроритмические признаки, знаки препинания	0.9089	0.8478	0.7893
слова, отношения, 2-3-граммы букв, метроритмические признаки, знаки препинания	0.9135	0.8469	0.7908

На рисунке 4 представлена диаграмма, описывающая важность признаков для классификации по группам признаков с использованием метода Шепли, признаки дополнены префиксами, указывающими на их принадлежность к группам. Главными признаками по-прежнему являются признаки, описывающие предпочтения авторов в знаках препинания, согласно которым Пушкин, предпочитал использование точек и многоточий, а не восклицательных знаков, которые отличают остальных авторов. При анализе важных признаков, описывающих отношения, подтверждается, что для творчества Пушкина не характерно широкое использование функциональных слов, но присуще использование отношений-модификаторов (синтаксических единиц, уточняющих значение других элементов синтаксической структуры) и конъюнктивных отношений. Кроме того, признаки, описывающие предпочтения поэта в использовании окончаний и буквосочетаний, отмеченные при описании классификации по *n*-граммам символов, присутствуют среди важных признаков в итоговой классификации. Метр также вошел в набор значимых признаков.




Рис. 4. Распределение влияния признаков на результаты классификации по группам признаков.

В основном наборе данных использовались стихотворные произведения А. С. Пушкина, написанные им начиная с 1823 года. Для проверки построенной модели, переобученной на всем наборе данных, использовались 50 стихотворений А. С. Пушкина, написанных в 1821 и 1822 годах, а также 46 стихотворений Д. В. Веневитинова. В результате все стихотворения Пушкина были классифицированы верно, но 13 стихотворений Веневитинова были отнесены к стихотворениям Пушкина. Таким образом F_1 -мера для валидационной выборки составила 0.88. Для модели, обученной на стихотворениях не менее 16 строк, все 26 стихотворений Пушкина не менее 16 строк были классифицированы верно и из 39 стихотворений Веневитинова были неверно классифицированы 7, то есть данная модель показывает большую точность, но меньшую полноту: в некоторых случаях она может приписать Пушкину стихи других поэтов, но принадлежность стихотворений перу Пушкина определяет почти наверняка.

Таким образом, произведена оценка важности групп признаков стихотворных текстов для определения авторского стиля, также проведена оценка влияния характеристик нижнего уровня стихотворений (статистического и семантического) на их характеристики высшего уровня, прежде всего, на авторский стиль. Самую эффективную классификацию

по рассмотренным группам признаков удалось получить по 2-, 3- и 4-граммам знаков, классификация только по буквам и пробелам проигрывает классификации по знакам по точности. На следующем месте располагается классификация по словам. Все перечисленные классификации показали AUC ROC больше 0.8, но при этом количество признаков классификации в них исчислялось тысячами и десятками тысяч. Лучшая из построенных классификаций включила в себя все выбранные группы признаков: 2-, 3- и 4-граммы знаков, слова, знаки пунктуации, отношения и метроритмические признаки, при этом очевидно, что существуют непустые попарные пересечения признаков в этих группах.

В седьмой главе сформированы принципы создания программных систем автоматизированного многоуровневого анализа поэтических текстов, предназначенных для хранения поэтических текстов и их представления, состоящие в комплексности системы, взаимосвязанности анализируемых уровней, опоре на теоретические аспекты лингвистики, сочетании классических методов компьютерной лингвистики и современных методов, основанных на машинном обучении. Сформулированы требования к информационной системе представления результатов комплексного анализа поэтических текстов, описано проектирование и реализация пользовательского интерфейса. Следует отметить, что термин «информационная система» применяется в контексте данных разработок как обозначение соответствующего компонента программной системы комплексного анализа поэтических текстов. Представление широкого спектра извлеченных из поэтических текстов метаданных позволяет в автоматизированном режиме генерировать словари рифм, метроритмические справочники, словари языка поэтов, конкордансы.

Каждый модуль программной системы автоматизированного анализа поэтических текстов относится к одному из структурных уровней анализа текста. Процесс проектирования и реализации системы представления результатов анализа поэтических текстов включает в себя формулировку задач, которые призвана решать система, а также изложение требований в порядке приоритета для общего проекта. Разработанная система объединяет в себе разнородную информацию о результатах анализа поэтических текстов, полученных на каждом из уровней представления, согласно концептуальному описанию системы.

Созданная система обладает следующими возможностями:

1. Обеспечение доступа к корпусам поэтических текстов.
2. Автоматизированная обработка корпуса поэтических текстов, хранящихся в БД:
 - а) определение фонетических характеристик текста;
 - б) исследование метроритмических характеристик: метрика, стопность; рифмовка строфики и др. с указанием неоднозначностей, которые не могут быть разрешены автоматически;
 - в) определение лексических характеристик текста;
 - г) определение жанрово-стилевых характеристик текста.
3. Занесение полученных характеристик в хранилище (базу данных).
4. Статистическая обработка полученных характеристик и их представление в удобном для исследователя виде.
5. Возможность импорта корпусов поэтических текстов из баз данных и файлов, и их экспорта в другие информационные системы для дальнейшей автоматизированной обработки.

Сформулировано **концептуальное описание системы**, основная часть информационной системы реализована в виде базы данных, хранящей в себе как сами стихотворения, так и их характеристики (на данный момент в базе данных, состоящей из 24 таблиц, хранятся произведения трех авторов, в основных таблицах содержится 521 произведение общим объемом 27398 слов). Интерфейс доступен по адресу: http://db4.sbras.ru/~poems_user/IS. Результаты работы показали принципиальную возможность интеграции упомянутых последовательно выше, в соответствующих главах диссертационной работы, компонентов

системы.

Концептуальное описание программной системы следующее. Система описывает следующие типы сущностей:

1. Авторы.
2. Тексты.
3. Лексемы.
4. Рифмы.
5. Метроритмические характеристики (фактуры).
6. Жанры.
7. Стили.

Центральным компонентом является система хранения текстов и их метаданных. Базовый элемент описания — слово в каждом своем вхождении в поэтический текст. Предлагается четырехуровневое кодирование каждого слова четырьмя индексами: 1. ID Автор. 2. ID Стихотворение. 3. ID Строка в стихотворении. 4. ID Слово в строке.

Система позволяет автоматически генерировать следующие словари и справочники, основные для филолога-стиховеда:

1. Лексический словарь.
2. Словарь языка.
3. Конкорданс.
4. Словарь рифм.
5. Метроритмический справочник.

В лексическом словаре хранятся слова в начальной форме. Обращение к начальным формам слов позволяет получить словарь языка. Обращение к словоформам в контексте слов — конкорданс. Информация о каждой рифме представлена в виде n -арного отношения, где $n \geq 2$. Посредством обращения к этой компоненте организуется автоматическое составление словаря рифм.

Таким образом, разработанная программная система автоматизированного многоуровневого анализа поэтических текстов предназначена для хранения поэтических текстов, их представления посредством широкого спектра извлеченных метаданных, что позволяет в автоматизированном режиме генерировать словари рифм, метроритмические справочники, словари языка поэтов, конкордансы.

Заключение

Совокупность полученных в диссертационном исследовании результатов составляют технологические основы решения важной научно-технической проблемы автоматизированного многоуровневого анализа поэтических текстов, внедрение которых вносит значительный вклад в развитие отечественных информационных технологий. В ходе исследования получены следующие фундаментальные теоретические и практические результаты:

1. Обосновано соответствие между уровнями многоуровневой модели информации и уровнями структуры поэтического текста.
2. Разработана структура описания русского поэтического текста, отличительной особенностью которой является многоуровневость и наличие категориальных связей между уровнями.
3. Предложены алгоритмы фонетического анализа стихотворно-текстовой информации, опирающиеся на морфологическую структуру анализируемых лексем.
4. Исследованы принципы анализа метроритмических и строфических характеристик текста (фактур), основанные на единстве метроритмики и строфики.
5. Исследованы принципы и предложены алгоритмы составления конкордансов и справочников, извлечения словосочетаний, составления словарей языка поэтов, автоматизирующие снятие проблемы омографии.
6. Разработаны алгоритмы автоматизированного извлечения жанровых и стилевых характеристик, впервые основанные на методах машинного обучения.

7. Разработаны принципы создания программных систем автоматизированного многоуровневого анализа поэтических текстов, предназначенных для хранения поэтических текстов и их представления посредством широкого спектра извлеченных из них метаданных, что позволяет в автоматизированном режиме генерировать словари рифм, метроритмические справочники, словари языка поэтов, конкордансы.

Рекомендации, перспективы для дальнейшей разработки темы. Следует отметить направления дальнейших исследований, направленных на решение новых задач, связанных с решенными в диссертации:

— Для автоматизированного анализа нижних структурных уровней поэтического текста (фонетика, метроритмика, лексика) наиболее подходят прямые методы компьютерной лингвистики.

— Для анализа высших структурных уровней поэтического текста (синтаксис, семантика) перспективны методы машинного обучения, включая применение нейросетей.

— Наиболее интересным, с фундаментальной точки зрения, приложением разработанной системы является установление взаимозависимости между низшими и высшими уровнями структуры поэтического текста. Для этой цели самым подходящим представляется использование методов статистического анализа.

Приложение содержит свидетельства о регистрации программ и акты о внедрении результатов диссертации.

ОСНОВНЫЕ ПУБЛИКАЦИИ ПО ТЕМЕ ДИССЕРТАЦИИ

ПУБЛИКАЦИИ В ЖУРНАЛАХ, РЕКОМЕНДОВАННЫХ ВАК, ПО СПЕЦИАЛЬНОСТИ 05.13.17

1. **Барахнин В.Б., Кожемякина О.Ю., Забайкин А.В., Хаятова В.Д.** Автоматизация комплексного анализа русского поэтического текста: модели и алгоритмы // Вестник НГУ. Сер.: Информационные технологии. — 2015 — Т. 13. — Вып. 3. — С. 5—18.
2. **Барахнин В.Б., Федотов А.М., Бакиева А.М., Бакиев М.Н., Тажибаева С.Ж., Батура Т.В., Кожемякина О.Ю., Тусупов Д.А., Самбетбаева М.А., Лукпанова Л.Х.** Алгоритмы генерации и стемматизации словоформ казахского языка // Cloud of Science. — 2017. — Т. 4. — № 3. — С. 434—449.
3. **Барахнин В.Б., Кожемякина О.Ю., Рычкова Е.В., Пастушков И.С., Борзилова Ю.С.** Извлечение лексических и метроритмических признаков, характерных для жанра и стиля и их комбинаций в процессе автоматизированной обработки текстов на русском языке // Современные информационные технологии и ИТ-образование. — 2018. — Т. 14. — № 4. — С. 876—883. — <https://doi.org/10.25559/SITITO.14.201804.888-895>
4. **Барахнин В.Б., Кожемякина О.Ю., Рычкова Е.В., Борзилова Ю.С.** Автоматическое выделение словосочетаний из текстов славянского происхождения: сравнение подходов // Cloud of Science. — 2018. — Т. 5. — № 4. — С. 713—728.
5. **Барахнин В.Б., Кожемякина О.Ю., Борзилова Ю.С.** Проектирование информационной системы представления результатов комплексного анализа поэтических текстов // Вестник НГУ. Сер.: Информационные технологии. — 2019. — Т. 17. — Вып. 1. — С. 5—17. — <http://dx.doi.org/10.25205/1818-7900-2019-17-1-5-17>

6. **Барахнин В.Б., Кожемякина О.Ю., Кузнецова И.В., Тагирова Е.П., Борзилова Ю.С.** Разработка и практическая реализация алгоритмов создания электронных метроритмических справочников и конкордансов // *Cloud of Science*. — 2020. — Т. 7. — № 1. — С. 135—155.
7. **Барахнин В.Б., Кожемякина О.Ю., Борзилова Ю.С.** Оптимизация SQL-запросов на примере работы поискового модуля системы комплексного анализа художественных текстов // *Cloud of Science*. — 2020. — Т. 7. — № 4. — С. 749—763.
8. **Барахнин В.Б., Кожемякина О.Ю., Кузнецова И.В., Карпова В.А.** Модель фактуры русских поэтических текстов // *Вычислительные технологии*. — 2021. — Т. 26. — № 3. — С. 107—117. — <https://doi.org/10.25743/ICT.2021.26.3.007>
9. **Кожемякина О.Ю.** Концептуальное проектирование программной системы автоматизированного комплексного анализа поэтических текстов // *Вычислительные технологии*. — 2022. — Т. 27. — № 2. — С. 122—137. — <https://doi.org/10.25743/ICT.2022.27.2.010>.

ПУБЛИКАЦИИ В ИЗДАНИЯХ, ИНДЕКСИРОВАННЫХ Web of Science И/ИЛИ Scopus

10. **Барахнин В.Б., Кожемякина О.Ю.** Об автоматизации комплексного анализа русского поэтического текста // *CEUR Workshop Proceedings*. — 2012. — V. 934. — P. 167—171.
11. **Барахнин В.Б., Кожемякина О.Ю., Забайкин А.В.** Алгоритмы комплексного анализа русских поэтических текстов с целью автоматизации процесса создания метрических справочников и конкордансов // *CEUR Workshop Proceedings*. — 2015. — V. 1536. — P. 138—143.
12. **Barakhnin V.B., Kozhemyakina O.Yu., Zabaykin A.V.** Usage of modern computer technologies in the learning process of the philologists of complex analysis of Russian poetic texts // *SHS Web of Conferences*. — Volume 29 (2016). — 2016 International Conference «Education Environment for the Information Age» (EEIA-2016). — Moscow, Russia, June 6-7, 2016. — 5 p. — <http://dx.doi.org/10.1051/shsconf/20162902002>
13. **Barakhnin V., Kozhemyakina O., Pastushkov I.** Automated determination of the type of genre and stylistic coloring of Russian texts // *ITM Web of Conferences* 10, 02001 (2017). — Volume 10 (2017). — 2017 Seminar on Systems Analysis. — Moscow, Russia, February 14-15, 2017. — 4 p. — <https://doi.org/10.1051/itmconf/20171002001>
14. **Barakhnin V.B., Fedotov A.M., Bakiyeva A.M., Bakiyev M.N., Tazhibayeva S.Zh., Batura T.V., Kozhemyakina O.Yu., Tussupov D.A., Sambetbaiyeva M.A., Lukpanova L.Kh.** The software system for the study the morphology of the Kazakh language // *The European Proceedings of Social & Behavioural Sciences*. — 2017. — V. XXXIII. — P. 18—27. — <http://dx.doi.org/10.15405/epsbs.2017.12.3>
15. **Барахнин В.Б., Кожемякина О.Ю., Пастушков И.С.** Сравнительный анализ методов автоматической классификации поэтических текстов на основе лексических признаков // *CEUR Workshop Proceedings*. — 2017. — V. 2022. — P. 252—257.
16. **Barakhnin V.B., Kozhemyakina O.Yu., Kuznetsova I.V.** Development and implementation of the algorithm for automatic analysis of metrorhythmic characteristics of Russian poetic texts // *CEUR Workshop Proceedings*. — 2019. — V. 2523. — P. 290—298.
17. **Barakhnin V.B., Kozhemyakina O.Yu., Mukhamediev R.I., Borzilova Yu.S., Yakunin K.O.** The design of the structure of the software system for processing text document corpus // *Business Informatics*. — 2019. — Vol.13. — N 4. — P. 60—72. — <http://dx.doi.org/10.17323/1998-0663.2019.4.60.72>
18. **Barakhnin V.B., Kozhemyakina O.Yu., Pastushkov I.S.** The effective interaction of the models of classification with the usage of auction heuristics // *Journal of Physics: Conference*

Series. — 2021. — Vol. 1727. — Art.012012. — <http://doi.org/10.1088/1742-6596/1727/1/012012>

19. **Barakhnin V., Kozhemyakina O., Revun A., Shashok N.** Technological features of cross-language migration from PHP to Python of software products working with intensive data // CEUR Workshop Proceedings. — 2021. — V. 3036. — P. 411—421.
20. **Barakhnin V., Kozhemyakina O., Grigorieva I.V.** Determination of the features of the author's style of A.S. Pushkin's poems by machine learning methods // Applied Sciences. — 2022. — 12. — 1674. — <https://doi.org/10.3390/app12031674>

ПУБЛИКАЦИИ В ДРУГИХ ИЗДАНИЯХ

21. **Барахнин В.Б., Кожемякина О.Ю., Соколова О.С., Альменова А.Б., Енсегенова А.А., Садуахас Н.С., Ыдырыс Ж.С.** О применении компьютерных технологий в анализе поэтических текстов // Сборник трудов конференции «Информационно-вычислительные технологии и математическое моделирование» (ИВТ&ММ). Кемерово, 23-30 июня 2013). — Кемерово: КемГУ. — 2013. — Режим доступа: файл [Гос. регистр. № 0321302759].
22. **Барахнин В.Б., Кожемякина О.Ю., Забайкин А.В.** Технология создания метрических справочников и конкордансов русских поэтических текстов // Вычислительные технологии, т. 20, Вестник КазНУ им.аль-Фараби, Серия математика, механика и информатика, № 3 (86), 2015, совместный выпуск. — Часть IV. — С. 54—60.
23. **Барахнин В.Б., Кожемякина О.Ю., Забайкин А.В.** Алгоритмы комплексного анализа русских поэтических текстов с целью автоматизации процесса создания метрических справочников и конкордансов // Аналитика и управление данными в областях с интенсивным использованием данных: Семнадцатая Международная конференция DAMID/RCDL'2015. — Обнинск, 13—16 октября 2015 г. — С. 253—266.
24. **Barakhnin V., Kozhemyakina O., Zabaykin A.** Algorithms for automation of the complex analysis of Russian poetic texts // The 14th International Scientific Conference «Information Technologies and Management». — Riga, April 14-15, 2016. — Riga: ISMA University, 2016. — ISSN 1691-2489. — P. 133—135.
25. **Барахнин В.Б., Кожемякина О.Ю., Пастушков И.С.** Разработка алгоритмов автоматизированного определения жанрового типа и стилистической окраски текстов на русском языке // Аналитика и управление данными в областях с интенсивным использованием данных: Восемнадцатая Международная конференция DAMID/RCDL'2016. — Ершово, Москва, 11-14 октября 2016 г. — С. 349—350.
26. **Барахнин В.Б., Кожемякина О.Ю., Пастушков И.С.** Использование метода опорных векторов для автоматизированного определения жанрового типа и стилистической окраски текстов на русском языке // Труды Седьмой международной конференции «Системный анализ и информационные технологии». — Светлогорск, 13-18 июня 2017 г. — С. 198—201.
27. **Барахнин В.Б., Кожемякина О.Ю., Тагирова Е.П.** Алгоритм перевода текстов из дореформенной орфографии в современную с учетом морфологии слов // Восьмая Международная конференция «Системный анализ и информационные технологии» САИТ — 2019: Труды конференции. — 2019. — М.: ФИЦ ИУ РАН. — С. 199—206. — ISBN 978-5-904466-62-6.

СВИДЕТЕЛЬСТВА О ГОСУДАРСТВЕННОЙ РЕГИСТРАЦИИ ПРОГРАММЫ ДЛЯ ЭВМ

28. **Барахнин В.Б., Кожемякина О.Ю., Кузнецова И.В.** Программа автоматического анализа метроритмических характеристик поэтических текстов на русском языке // Свидетельство о государственной регистрации программы для ЭВМ № 2020663072 от 22.10.2020 г. — Заявка № 2020662151 от 12.10.2020 г. (Федеральная служба по интеллектуальной собственности). —
<https://www1.fips.ru/ofpstorage/Doc/PrEVM/RUNWPR/000/002/020/663/072/2020663072-00001/document.pdf>
29. **Барахнин В.Б., Кожемякина О.Ю., Карпова В.А., Кузнецова И.В.** Программа определения фактур русских поэтических текстов // Свидетельство о государственной регистрации программы для ЭВМ № 2021664226 от 01.09.2021 г. — Заявка № 20216163325 от 24.08.2021 г. (Федеральная служба по интеллектуальной собственности).
<https://new.fips.ru/ofpstorage/Doc/PrEVM/RUNWPR/000/002/021/664/226/2021664226-00001/document.pdf>

СВИДЕТЕЛЬСТВО О ГОСУДАРСТВЕННОЙ РЕГИСТРАЦИИ БАЗЫ ДАННЫХ

30. **Барахнин В.Б., Кожемякина О.Ю., Борзилова Ю.С.** Русские поэтические тексты и их комплексные стиховедческие метаданные // Свидетельство о государственной регистрации базы данных № 2020621889 от 15.10.2020 г. — Заявка № 2020621862 от 28.09.2020 г. (Федеральная служба по интеллектуальной собственности).
<https://www.fips.ru/ofpstorage/Doc/PrEVM/RUNWDB/000/002/020/621/889/2020621889-00001/document.pdf>

Подписано в печать 15.06.2022
Формат бумаги 60х84 1/16

Объем 2 изд.л.
Тираж 120 экз.

Заказ № 15
Отпечатано в типографии ООО «Ареал»
630058, г. Новосибирск, ул. Русская, д. 41, оф. 14.
Тел. +7 (383) 287–87–59