



На правах рукописи

ГУДКОВ Алексей Анатольевич

**АВТОМАТИЗИРОВАННАЯ СИСТЕМА МОНИТОРИНГА
СОЦИАЛЬНО-ЭКОНОМИЧЕСКОЙ СФЕРЫ РЕГИОНА
НА ОСНОВЕ ТЕХНОЛОГИЙ ОБНАРУЖЕНИЯ ЗНАНИЙ
В БАЗАХ ДАННЫХ**

**Специальность 05.13.10 – Управление в социальных
и экономических системах (технические науки)**

А в т о р е ф е р а т
диссертации на соискание ученой степени
кандидата технических наук

21 НОЯ 2008

ПЕНЗА 2008

Работа выполнена в государственном образовательном учреждении высшего профессионального образования «Пензенский государственный университет».

Научный руководитель – доктор технических наук, профессор
Бершадский Александр Моисеевич.

Официальные оппоненты: доктор технических наук, профессор
Камаев Валерий Анатольевич
(Волгоградский государственный
технический университет, г. Волгоград);
доктор технических наук, профессор
Макаров Алексей Алексеевич
(Международный институт рынка,
г. Самара).

Ведущая организация – Исследовательский центр проблем качества подготовки специалистов (г. Москва).

Защита диссертации состоится 11 декабря 2008 г., в 14 часов, на заседании диссертационного совета Д 212.186.04 в государственном образовательном учреждении высшего профессионального образования «Пензенский государственный университет» по адресу: 440026, г. Пенза, ул. Красная, 40.

С диссертацией можно ознакомиться в библиотеке государственного образовательного учреждения высшего профессионального образования «Пензенский государственный университет», автореферат размещен на сайте www.pnzgu.ru

Автореферат разослан 10 ноября 2008 г.

Ученый секретарь
диссертационного совета
доктор технических наук,
профессор

Смогунов В. В.

ОБЩАЯ ХАРАКТЕРИСТИКА РАБОТЫ

Актуальность темы. Управление социально-экономическими (СЭ) объектами подразумевает выполнение определенной последовательности действий: сбор информации об объекте управления; анализ полученной информации; принятие решения; управляющее воздействие; контроль. Первые два этапа, относящиеся к сбору и анализу информации, составляют основу понятия «мониторинг». Таким образом, мониторинг можно определить как составную часть процесса управления, заключающуюся в систематическом наблюдении и анализе деятельности объекта управления. Следовательно, для принятия обоснованных управленческих решений региональным органам власти необходимы современные средства и методы сбора и анализа СЭ-информации. Особую актуальность проблема мониторинга приобретает тогда, когда информация об исследуемой системе сложно структурирована и отражает различные стороны ее функционирования, что характерно для СЭ-сферы региона.

Проблемой регионального мониторинга занимаются такие ведущие организации, как Центральный экономико-математический институт РАН, Институт экономики Карельского научного центра РАН, Ивановский государственный энергетический университет, компании «Прогноз», «ИНЭК», «ПАРУС» и др.

Данная работа направлена на разработку новых подходов к мониторингу СЭ-сферы региона, позволяющих повысить его качество. Для этих целей предлагается использовать технологии обнаружения знаний в базах данных (Knowledge Discovery in Databases, KDD), к которым можно отнести технологии хранилищ данных, многомерных баз данных, технологии оперативной и интеллектуальной обработки данных, геоинформационные технологии.

Цель и задачи исследования. Целью диссертационной работы являются исследование проблемы регионального мониторинга и анализа СЭ-информации, поиск путей повышения качества мониторинга, а также разработка автоматизированной системы мониторинга на основе технологий KDD и методики ее применения на примере региональных СЭ-данных. Для достижения поставленной цели необходимо решить следующие задачи:

1. Анализ существующих методов мониторинга, выявление их достоинств и недостатков; анализ применимости процесса KDD к задаче мониторинга СЭ-сферы региона.

2. Анализ существующих алгоритмов интеллектуального анализа данных (Data Mining) и возможности их применения к региональным СЭ-данным; разработка алгоритмов Data Mining, специфичных для СЭ-сферы.

3. Проектирование автоматизированной системы мониторинга на основе технологий KDD, определение ее структуры и функций входящих в нее модулей; разработка программного и информационного обеспечения системы.

4. Апробация разработанной системы; экспериментальное исследование всех этапов мониторинга в рамках процесса KDD; составление рекомендаций по проведению мониторинга СЭ-сферы региона с использованием разработанной системы.

Методы исследования. При решении поставленных задач использовались принципы и методы системного анализа, модульного и объектно-ориентированного проектирования и программирования, теории баз данных, математической статистики, факторного анализа, геоинформационного пространственного анализа.

Научная новизна исследования состоит в следующем:

1. Впервые предлагается использовать технологии KDD (в том числе методы Data Mining) для мониторинга СЭ-сферы региона, что позволит устранить недостатки, присущие традиционным методам мониторинга, и повысить качество мониторинга.

2. Предложен новый алгоритм Data Mining, специфичный для СЭ-исследований, – алгоритм конструирования интегральных показателей, позволяющий выявлять латентные признаки в исследуемых системах, ранжировать объекты, выявлять признаки, обуславливающие социальное или экономическое развитие отдельных регионов (или, наоборот, их депрессию) и др.

3. Предложена структура автоматизированной системы мониторинга, поддерживающей все этапы процесса KDD: сбор данных, их очистку, консолидацию, интеллектуальный анализ данных, вывод и интерпретацию результатов, – с учетом специфики предметной области.

4. Разработана методика проведения анализа СЭ-информации с использованием алгоритмов Data Mining. Отличительной особенностью предлагаемого подхода является разработанный механизм генерирования рекомендаций для лица, принимающего решения, на основе результатов интеллектуального анализа данных.

Практическая ценность. Предлагаемый новый подход к мониторингу СЭ-систем на основе технологий KDD позволяет эффективно аккумулировать СЭ-информацию из различных источников; выполнять анализ больших групп СЭ-показателей в их системном единстве; повысить оперативность анализа; обнаруживать скрытые закономерности в данных; более выразительно представлять результаты анализа. Все это способствует принятию более обоснованных управленческих решений.

Разработано программное и информационное обеспечение автоматизированной системы мониторинга, имеющей в своем составе подсистемы очистки данных, формирования структуры многомерной базы данных, ввода и редактирования данных, интеллектуального анализа информации и др., функционирующие на платформах Win32 и .NET (Windows 2000/XP/2003). В рамках подсистемы интеллектуального анализа информации разработано программное обеспечение, реализующее алгоритм конструирования интегральных показателей.

Даны практические рекомендации по использованию разработанной автоматизированной системы мониторинга, предложены и описаны последовательность и содержание этапов мониторинга СЭ-информации.

Основные положения, выносимые на защиту:

1. Применение технологий KDD (в том числе методов Data Mining) для мониторинга СЭ-сферы региона.

2. Новый алгоритм Data Mining – алгоритм конструирования интегральных показателей, позволяющий ранжировать объекты, а также выявлять признаки, обуславливающие СЭ-развитие отдельных территорий.

3. Структура автоматизированной системы мониторинга СЭ-сферы региона на основе технологий KDD.

4. Методика анализа региональных СЭ-данных с использованием алгоритмов Data Mining, включающая генерирование рекомендаций для лица, принимающего решения.

Внедрение результатов работы. Основные теоретические и практические результаты диссертационной работы использовались при выполнении темы «Разработка и апробация методики оценки состояния и оптимизации региональной сети профессионального образования с учетом решения задач формирования общенациональных университетов и системообразующих вузов. Создание регионального модуля системы информационно-аналитического обеспечения» (договор от 18 сентября 2007 г. № 3/П637 в рамках ГК № 63/М-Н-3874 р от 17.09.07).

Кроме того, результаты работы использовались при выполнении НИР «Разработка методики информационной поддержки подготовки и переподготовки государственных и муниципальных служащих в области информационных технологий» по заказу Тамбовского государственного технического университета (договор № 05/07 от 1 февраля 2007 г.), о чем имеется акт внедрения.

Апробация работы. Основные положения и результаты диссертационной работы докладывались и обсуждались на следующих конференциях и семинарах: X, XI, XII Международных научно-методических конференциях «Университетское образование» (Пенза, 2006–2008), конференции «Технологии Microsoft в теории и практике программирования» (Нижний Новгород, 2006), Всероссийской научно-практической конференции «Развитие университетского комплекса как фактор повышения инновационного и образовательного потенциала региона» (Оренбург, 2007), XXXIV Международной конференции «Информационные технологии в науке, социологии, экономике и бизнесе IT+SE'07» (Ялта–Гурзуф, 2007), XIV, XV Всероссийских научно-методических конференциях «Телематика'2007, '2008» (Санкт-Петербург, 2007–2008), I Всероссийской научно-практической конференции «Информационные технологии в образовании, науке и производстве» (Серпухов, 2007), II Международной конференции «Аналитические и численные методы моделирования естественнонаучных и социальных проблем» (Пенза, 2007), XIII Всероссийской научно-технической конференции «Новые информационные технологии в научных исследованиях и образовании» (Рязань, 2008), научно-практической конференции «Перспективные технологии искусственного интеллекта» (Пенза, 2008), научно-технических конфе-

рениях профессорско-преподавательского состава Пензенского государственного университета (2006–2008).

Публикации. По материалам диссертации опубликовано 16 печатных работ.

Структура и объем работы. Диссертация состоит из введения, четырех глав, заключения, списка литературы, включающего 141 наименование, приложения, содержащего акт внедрения. Основная часть работы изложена на 174 машинописных страницах, содержит 45 рисунков и 16 таблиц.

ОСНОВНОЕ СОДЕРЖАНИЕ РАБОТЫ

Во введении обоснована актуальность темы диссертации, сформулированы цели и задачи исследования, отражена научная новизна и приведены основные практические результаты работы.

В первой главе рассматриваются существующие методы и системы мониторинга СЭ-сферы региона, а также технологии процесса KDD.

Анализ существующих методов мониторинга СЭ-сферы региона позволил выявить присущие им недостатки: ограниченная возможность совместного анализа больших групп СЭ-показателей в их системном единстве; неиспользование преимуществ, вытекающих из иерархической структуры региональных СЭ-данных; использование традиционных статистических методов анализа, не позволяющих выявлять глубинные закономерности, скрытые в больших массивах СЭ-данных, и др.

Для устранения выявленных недостатков предлагается использовать в процессе регионального мониторинга информационно-аналитический комплекс, построенный на базе технологий обнаружения знаний в базах данных (KDD), включающих в себя технологии хранилищ данных, многомерных баз данных, оперативного и интеллектуального анализа, геоинформационные технологии. Использование многомерных баз данных позволяет эффективно аккумулировать СЭ-информацию из различных источников; технология оперативного анализа (OLAP) позволяет в реальном времени получать различные «срезы» многомерного куба данных и выполнять операции детализации/обобщения данных; технология интеллектуального анализа позволяет выявлять в СЭ-данных скрытые закономерности и совместно

с геоинформационными технологиями более выразительно представлять результаты анализа.

KDD – это процесс преобразования данных к знаниям. Под *данными* понимается информация, представленная в формализованном виде, пригодном для обработки в некотором информационном процессе. Под *знаниями* понимается информация о закономерностях процессов и явлений, их причинно-следственных связях. Главное отличие знаний от данных состоит в их активности, т. е. в возможности их использования для принятия решений. KDD включает в себя вопросы подготовки данных, выбора информативных признаков, очистки данных, применения методов Data Mining, постобработки данных, интерпретации полученных результатов.

Проведенный анализ современного состояния систем и инструментальных средств, используемых для анализа региональной СЭ-информации, позволил выявить их недостатки: для специализированных систем – это полное или частичное отсутствие поддержки процесса KDD и методов интеллектуального анализа данных, что делает невозможным выявление глубинных закономерностей, присущих исследуемым СЭ-системам; для универсальных систем – это чрезмерная сложность, малая пригодность для целей мониторинга (больше предназначены для анализа информации), а также отсутствие аналитических методов, специфичных для СЭ-систем. В связи с этим был сделан вывод о необходимости разработки системы мониторинга СЭ-сферы региона с использованием технологий KDD.

Во второй главе рассматриваются модели и методы интеллектуального анализа данных, являющегося основой процесса KDD. В частности, исследуется возможность применения широко известных алгоритмов Data Mining к региональным СЭ-данным. Предлагается алгоритм конструирования интегральных показателей как алгоритм Data Mining, специфичный для исследования СЭ-явлений.

Ключевым в процессе KDD является этап интеллектуального анализа данных. Набор методов интеллектуального анализа не является строго фиксированным, а базируется на разнообразных алгоритмических и статистических методах, методах нечеткой логики, генетических алгоритмах, нейронных сетях и т. д. Характерной особенностью интеллектуального анализа данных является то, что получаемые в итоге знания должны обладать следующими свойствами: быть ранее

не известными, нетривиальными и практически полезными. В отличие от оперативной аналитической обработки данных (OLAP), в Data Mining задача формулировки гипотез и выявления необычных шаблонов в данных переложена с человека на компьютер.

При анализе СЭ-явлений особую актуальность представляет исследование ситуаций, характеризующихся большим количеством различных свойств, каждое из которых является существенным для характеристики данного явления. В такого рода ситуациях часто требуется сконцентрировать информацию, выражая большое число исходных косвенных признаков через меньшее число более емких внутренних характеристик явления. Более того, часто аналитик сталкивается с ситуациями, когда ему приходится сравнивать между собой или упорядочивать ряд сложных систем по некоторому не поддающемуся непосредственному измерению одному признаку. Речь может идти, в частности, о сравнении регионов по уровню или качеству жизни, предприятий отрасли – по эффективности их деятельности и т. д. При этом общее представление о степени проявления анализируемого латентного, не поддающегося непосредственному измерению свойства складывается как результат определенного суммирования целого ряда частных поддающихся измерению характеристик, от которых зависит в конечном счете это свойство. Таким образом, встает задача конструирования интегрального показателя (ИП). Принимая во внимание определение понятия Data Mining, задачу построения интегральных показателей можно отнести к задачам интеллектуального анализа данных.

Проведенный обзор систем, ориентированных на интеллектуальный анализ данных, показал, что в них отсутствуют алгоритмы конструирования ИП. Это связано, в первую очередь, с тем, что изначально системы Data Mining разрабатывались для решения бизнес-задач, поэтому в них отсутствуют некоторые инструменты анализа, специфичные для СЭ-исследований.

Существует несколько подходов к построению ИП. Один из них заключается в замене исходного набора показателей рангами (местами), которые занимают объекты, с последующим усреднением этих рангов. Недостатками рангового подхода являются лишь упорядочивание объектов и, как следствие, невозможность определения степени неравенства между объектами. Другой подход заключается в

предварительном сведении показателей к одной размерности с последующим взвешенным суммированием. К недостаткам данного подхода можно отнести трудности с подбором весовых коэффициентов, а также то, что среди множества показателей, скорее всего, имеются коррелирующие между собой, которые будут вносить «лишний» вклад в ИП. Другие подходы основаны на сокращении пространства признаков путем экспертного отбора наиболее существенных признаков либо на основе анализа матрицы парных корреляций – в этом случае устраняются максимально коррелирующие между собой признаки. Главным недостатком таких подходов является возможность существенного искажения содержательного смысла СЭ-модели из-за исключения из нее потенциально важных показателей.

Справиться с отмеченными недостатками позволяет следующий двухэтапный метод построения ИП. На первом этапе происходит сокращение размерности исходного пространства признаков. Для этих целей используется метод главных компонент (один из методов факторного анализа). Получаемый в результате применения этого метода сокращенный набор признаков (факторов) обладает тем важным свойством, что признаки внутри него независимы. На втором этапе сокращенный набор независимых признаков предлагается объединять в ИП, используя экспертно-статистический подход. Математический аппарат предлагаемого метода построения ИП следующий.

Пусть имеется n исходных признаков, описывающих некоторую СЭ-систему. Будем рассматривать эти признаки как случайные величины и запишем их в виде вектора $\mathbf{Z} = (Z_1, Z_2, \dots, Z_n)^T$, где Z_i – центрированная случайная величина, соответствующая i -му признаку. Вычислим для вектора $\mathbf{Z}$ ковариационную матрицу $\Sigma = \mathbf{M}[\mathbf{Z} \mathbf{Z}^T]$. Будучи симметричной и неотрицательно определенной, она имеет n вещественных неотрицательных собственных чисел $\lambda_1, \lambda_2, \dots, \lambda_n$. Предположим, что $\lambda_1 > \lambda_2 > \dots > \lambda_n$.

Обозначим

$$\Lambda = \begin{pmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \dots & \dots & \ddots & \dots \\ 0 & 0 & \dots & \lambda_n \end{pmatrix}.$$

Пусть $\mathbf{v}_j = (v_{1j}, v_{2j}, \dots, v_{nj})^T$ – нормированные собственные векторы матрицы Σ , соответствующие собственным числам λ_j .

Введем матрицу $\mathbf{V} = (\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n)$. Так как $\Sigma \mathbf{v}_j = \lambda_j \mathbf{v}_j$, то

$$\mathbf{v}_j^T \Sigma \mathbf{v}_p = \lambda_j \mathbf{v}_j^T \mathbf{v}_p = \begin{cases} \lambda_j, & p = j, \\ 0, & p \neq j \end{cases}$$

и $\mathbf{V}^T \Sigma \mathbf{V} = \Lambda$.

Введем вектор $\mathbf{F} = \mathbf{V}^T \mathbf{Z}$. Его ковариационная матрица равна

$$\mathbf{M}[\mathbf{F} \mathbf{F}^T] = \mathbf{M}[\mathbf{V}^T \mathbf{Z} \mathbf{Z}^T \mathbf{V}] = \mathbf{V}^T \mathbf{M}[\mathbf{Z} \mathbf{Z}^T] \mathbf{V} = \mathbf{V}^T \Sigma \mathbf{V} = \Lambda.$$

Следовательно, компоненты вектора $\mathbf{F} = (F_1, F_2, \dots, F_n)^T$ не коррелированы, и их можно рассматривать в качестве искомым независимых факторов. Для их вычисления используется формула

$$F_j = \sum_{i=1}^n v_{ij} Z_i, \text{ при этом дисперсия факторов равна } \mathbf{D}[F_j] = \lambda_j.$$

Для построения единого ИП берутся первые $n' < n$ главных компонент с максимальными значениями λ , которыми исчерпывается не менее 55–70 % дисперсии исходных случайных величин. Поскольку главные компоненты независимы, для их объединения в ИП

предлагается использовать линейную свертку: $I_j = \sum_{i=1}^{n'} c_i F_{ij}$, где

$c_i = (e_i + d_i)/2$ – весовые коэффициенты факторов; e_i – экспертные оценки значимости факторов; d_i – оценки, вычисленные автоматически на основе анализа значений факторов. В качестве d_i предлагается использовать среднеквадратические отклонения факторов: $d_i = \sqrt{\mathbf{D}[F_i]} = \sqrt{\lambda_i}$.

В случае если имеются достаточно надежные экспертные оценки важности факторов, то вместо обобщенных весов c_i можно использовать только веса, полученные на основе экспертных оценок e_i . Наоборот, если получение экспертных оценок затруднено, то для оценки важности факторов можно использовать только веса, отражающие разброс значений факторов d_i .

Таким образом, впервые предлагается новый алгоритм Data Mining – алгоритм конструирования ИП, схема которого приведена на рис. 1. Построение ИП как метод Data Mining имеет следующие преимущества: единый подход к проведению интеллектуального анализа данных наравне с другими методами Data Mining; интеграция в общий процесс KDD; оперативность построения ИП и др.




Рис. 1. Схема алгоритма построения интегрального показателя

В третьей главе рассматривается автоматизированная система мониторинга СЭ-сферы региона (АСМ), а также предлагается методика проведения мониторинга с использованием данной системы. Структура АСМ, представленная на рис. 2, проектировалась, исходя из задач, встающих перед пользователем, исследующим данные с использованием технологий KDD.




Рис. 2. Структура автоматизированной системы мониторинга

Система реализована в виде клиент-серверного приложения, позволяющего клиентам подключаться к серверу по протоколу TCP/IP. В качестве сервера используется компонент Microsoft SQL Server 2005 Analysis Services. Основным преимуществом компонента Analysis Services является то, что он включает в себя две основные и дополняющие друг друга функциональные части – OLAP и Data Mining, которые являются основой для создания аналитических приложений, следующих технологиям KDD.

В соответствии с этапами процесса KDD была разработана методика проведения мониторинга СЭ-сферы региона. На первом этапе осуществляется анализ доступных источников информации и определяется совокупность данных (возможно, разрозненных или слабо

структурированных), на основании которых будет проводиться мониторинг.

Затем осуществляется проектирование структуры многомерной базы данных (МБД) в соответствии с имеющимися источниками данных и целями мониторинга. Для этого предназначена *подсистема формирования структуры МБД*, позволяющая визуально создавать требуемую структуру многомерного куба. Результатом работы данной подсистемы является XML-файл, в котором хранится описание структуры МБД.

Учитывая специфику предметной области, целесообразно использовать МБД с тремя измерениями: «объекты», «признаки», «время». При этом все измерения должны иметь иерархическую структуру, обусловленную иерархическим представлением СЭ-информации в тематическом плане, а также в пространственной и временной организации. Представление информации в виде такого куба позволяет аналитику исследовать различные аспекты СЭ-сферы региона: изменение значений признаков, описывающих один объект, во времени; пространственные различия (различия множества объектов по набору признаков); изменение одного признака во времени и в пространстве (на множестве объектов и на множестве интервалов времени).

Следующим идет этап очистки данных. Необходимость этого этапа определяется тем, что лишь немногие источники данных обеспечивают удовлетворительный контроль информации. Данный этап особо актуален при использовании средств сканирования и распознавания изображений, которые применяются при вводе информации, имеющейся в печатном виде. В связи с этим была разработана *подсистема очистки и форматирования данных*, реализованная в виде приложения, взаимодействующего с Microsoft Excel, и предназначенная для устранения различных опечаток и неточностей в табличных данных.

Следующим этапом является занесение информации в хранилище данных. Для этого были разработаны *подсистема ввода и редактирования данных*, а также *подсистема формирования МБД*. Первая предназначена для занесения данных из различных источников в единую реляционную базу данных. Эта подсистема позволяет также редактировать данные, в частности, устранять дублирование объектов, имеющих разные названия. Данные можно как импортировать из

уже существующих баз данных, так и заносить из таблиц Excel. Во втором случае в рассматриваемой подсистеме нужно выбрать два измерения, соответствующих строкам и столбцам заносимой таблицы (среза данных), а остальные измерения зафиксировать, придав им конкретные значения. *Подсистема формирования МБД* взаимодействует с Analysis Services и создает на сервере в соответствии с разработанной структурой МБД и на основе данных из реляционной базы данных многомерный куб.

Далее следует этап интеллектуального анализа данных. Данный этап можно разбить на три подэтапа:

- применение методов Data Mining;
- визуализация результатов Data Mining, в том числе отображение пространственных данных на электронных географических картах;
- интерпретация полученных результатов и генерирование рекомендаций для лица, принимающего решения.

Для выполнения этих действий предназначена *подсистема интеллектуального анализа информации* (клиентская часть), реализованная в виде приложения, работающего на платформе .NET и взаимодействующего с сервером Analysis Services посредством объектов ADOMD.NET и языка SQL с расширениями DMX (Data Mining eXtensions). Выборка нужного для анализа среза многомерного куба данных осуществляется с использованием компонента Microsoft Excel «сводная таблица». Сервер Analysis Services предоставляет клиентской части следующие алгоритмы Data Mining: деревья решений (decision trees), кластеризацию, простой байесовский алгоритм (naive bayes), ассоциативные правила, кластеризацию последовательностей (sequence clustering), алгоритм временных рядов, нейронные сети, линейную регрессию, логистическую регрессию, а также алгоритмы сторонних разработчиков (third-party plug-in algorithms).

Анализ региональных СЭ-данных рекомендуется начинать с алгоритма кластеризации, алгоритма ассоциативных правил или байесовского алгоритма. Если аналитик не уверен, какие показатели выбрать в качестве входных, рекомендуется выбрать все – большинство алгоритмов Data Mining автоматически отберет наиболее информативные переменные в плане их влияния на целевую переменную.

На основе результатов интеллектуального анализа данных клиентская подсистема генерирует рекомендации для лица, принимающего решения. Рекомендации строятся следующим образом: пользователь выбирает целевую переменную, задает ее целевое значение (минимум, максимум, среднее значение, конкретное значение или диапазон), и, основываясь на результатах алгоритмов Data Mining (кластеризации, байесовского алгоритма, ассоциативных правил), подсистема определяет значения, которые должны принимать остальные переменные, чтобы удовлетворить заданным условиям для целевой переменной. Например, при построении рекомендаций на основе кластерного анализа осуществляется поиск кластера, в котором значение целевого показателя наиболее близко к заданному значению. Затем анализируются значения других показателей, вошедших в данный кластер, и они выводятся в рекомендации в порядке убывания важности, которая определяется разбросом значений показателей среди кластеров.

Помимо генерирования рекомендаций, подсистема интеллектуального анализа информации позволяет строить интегральные показатели, а также отображать входные и выходные данные на электронных географических картах.

В четвертой главе рассматриваются вопросы, посвященные практическим аспектам применения разработанной системы. Приводятся результаты анализа показателей СЭ-развития регионов РФ, а также данных образовательной статистики по Пензенской и Тамбовской областям с использованием методов Data Mining. В частности, исследуются на практике такие методы интеллектуального анализа, как кластеризация, деревья решений, ассоциативные правила, байесовский алгоритм, нейронные сети и др.

С помощью алгоритма кластеризации проведено автоматическое разбиение вузов РФ по показателям формы 3-НК «Сведения о государственном и муниципальном высшем учебном заведении». Алгоритм выделил три кластера и определил, какие значения показателей характерны для каждого кластера. Значения некоторых показателей представлены в табл. 1, где жирным шрифтом отмечены максимальные значения, курсивом – минимальные.

Результаты кластеризации вузов

Показатель	Все записи	Кластер 1	Кластер 2	Кластер 3
% препод. в возрасте до 30 лет	17,01±5,93	13,88±4,59	17,89±5,9	21,57±4,78
% препод. в возрасте 30–39 лет	20,77±4,89	18,53±3,95	23,07±5,25	22,22±4,41
% препод. в возрасте 40–49 лет	20,71±5,61	19,76±4,1	24,6±7,31	18,2±3,33
% препод. в возрасте 50–59 лет	22,62±4,56	25,27±4,31	20,7±4,23	20,05±2,36
% препод. в возрасте 60–65 лет	8,73±3,6	10,17±3,73	7,48±3,62	7,57±2,27
% препод. в возрасте более 65 лет	10,15±5,13	12,4±5,36	6,26±3,25	10,39±3,85
% препод. на 0,5 и 0,25 ставки	13,88±6,39	11,87±4,39	14,36±6,16	16,89±8,25
% препод. на полной ставке	86,12±6,39	88,13±4,39	85,64±6,16	83,11±8,25
% препод. с ученым званием доцента	34,65±8,48	39,96±6,5	29,1±9,69	31,28±3,08
% препод. с ученым званием профессора	8,82±3,59	9,88±2,5	6,56±4,84	9,38±2,48
% препод. с ученой степенью кандидата наук	50,9±9,15	53,54±5,69	44,82±12,44	52,8±6,89
% препод. с ученой степенью доктора наук	10,13±3,84	10,97±2,58	7,15±4,83	11,87±2,6
% препод. на должности препод. или ассистента	17,39±7,95	13,65±6,2	19,11±7,6	22,08±8,13
% препод. на должности ст. препод.	22,72±7,62	21,39±6,05	28,86±7,96	18,46±5,56
% препод. на должности доцента	40,72±8,25	44,96±6,27	33,48±7,24	41,04±7,1
% препод. на должности профессора	7,53±3,32	8,29±3,19	5,76±3,99	8,1±1,79

С помощью алгоритма деревьев решений выполнена классификация субъектов РФ в зависимости от уровня преступности. Признаками, на основе которых производилась классификация, выступали показатели, характеризующие уровень образования безработного населения. Построенное дерево решений позволяет определить иерархию зависимостей уровня преступности в регионах от уровня образования населения. Пример автоматически построенного дерева показан на рис. 3, где жирным шрифтом отмечено среднее число преступлений на 100 000 чел. населения, характерное для данного класса регионов.

Применение алгоритма конструирования ИП для составления рейтинга регионов по множеству показателей, характеризующих качество жизни населения, позволило выявить, какие факторы положительно и отрицательно влияют на итоговое значение ИП. Таким образом, с помощью данного алгоритма можно определить проблемные области в СЭ-развитии территории.

В табл. 2 приведены результаты сравнения разработанной АСМ с некоторыми известными аналитическими системами, которые можно использовать в процессе KDD (знаком «+» отмечены функциональные возможности, имеющиеся в соответствующей системе, знаком «-» – отсутствующие, знаком «+/-» – присутствующие частично). Сравнение показало, что разработанная система превосходит анало-

гичные системы по параметрам, являющимся существенными при мониторинге СЭ-сферы региона.




Рис. 3. Дерево решений, классифицирующее регионы по уровню преступности

Таблица 2

Сравнение разработанной ACM с другими системами KDD

Аналитиче- ская систе- ма	Очистка данных	Транс- форма- ция данных	Возмож- ность подключе- ния к БД	Под- держка OLAP и МБД	Под- держка архи- тектуры «кли- ент- сервер»	Стати- стиче- ские методы	Стан- дартные алго- ритмы ИАД	Пост- роение ИП	Нагляд- ность результ- атов ИАД	Ото- браже- ние данных на карте
SPSS 13.0	+/-	+	+	-	+	+	КЛ, ДР, Р, ФА, ВР	-	+/-	-
Microsoft Business Intelligence Development Studio 2005	+/-	+/-	+	+	+	-	ДР, АП, НС, КЛ, Б, Р, ВР, КЛ	-	+	-
Deductor 5.1	+	+/-	+	+	+	+/-	ФА, ВР, Р, НС, ДР, АП, КЛ	-	+	-
Разрабо- танная ACM	+	+/-	+	+	+	-	ДР, АП, НС, КЛ, Б, Р, ВР, КЛ	+	+ (генера- рование реко- мenda- ций)	+

П р и м е ч а н и е. КЛ – кластеризация, ДР – деревья решений, Р – регрессия, ФА – факторный анализ, ВР – временные ряды, АП – ассоциативные правила, НС – нейронные сети, Б – байесовский алгоритм, КЛ – кластеризация последовательностей.

ОСНОВНЫЕ РЕЗУЛЬТАТЫ РАБОТЫ

1. Анализ существующих методов мониторинга СЭ-сферы региона позволил выявить присущие им недостатки, для устранения которых предлагается использовать информационно-аналитический комплекс, построенный на базе технологий многомерных баз данных, оперативного и интеллектуального анализа данных, геоинформационных технологий.

2. Впервые предлагается использовать технологию обнаружения знаний в базах данных (KDD) применительно к мониторингу СЭ-сферы региона, что позволит перевести мониторинг на качественно более высокий уровень, а также получить максимальный эффект от применения указанных выше информационных технологий.

3. Проведен анализ существующих систем, используемых при мониторинге и анализе СЭ-информации. Выявлены их недостатки, основным из которых является полное или частичное отсутствие поддержки процесса KDD и методов интеллектуального анализа данных, что делает невозможным выявление глубинных закономерностей, присущих исследуемым СЭ-системам. В связи с этим сделан вывод о необходимости разработки системы мониторинга СЭ-сферы региона на основе технологий KDD.

4. Предложен новый алгоритм Data Mining, позволяющий конструировать интегральные показатели, которые можно использовать для выявления латентных признаков, присущих СЭ-системам, ранжирования объектов, их сравнения, выявления признаков, обуславливающих социальное или экономическое развитие отдельных регионов, и др.

5. Предложена структура автоматизированной системы мониторинга, разработано ее программное и информационное обеспечение, реализующее все функции процесса KDD: ввод данных, их очистку, консолидацию в многомерную базу данных, интеллектуальный анализ данных, вывод и интерпретацию результатов.

6. Разработана методика проведения мониторинга СЭ-сферы региона на базе технологий KDD, в том числе методика анализа СЭ-информации с использованием алгоритмов интеллектуального анализа данных. Проведено практическое исследование распространенных методов Data Mining (кластеризация, деревья решений, ассоциа-

тивные правила, байесовский алгоритм, нейронные сети и др.) применительно к СЭ-данным, подтвердившее возможность их использования для выявления неочевидных закономерностей, присущих СЭ-сфере региона.

7. Экспериментальные исследования показали, что применение разработанной системы дает возможность учесть при анализе большие группы СЭ-показателей в их системном единстве, повысить оперативность анализа, выявить неочевидные закономерности в данных.

ОСНОВНЫЕ ПУБЛИКАЦИИ ПО ТЕМЕ ДИССЕРТАЦИИ

Публикация в издании, рекомендованном ВАК

1. Разработка методов информационно-аналитического обеспечения процесса подготовки и переподготовки государственных и муниципальных служащих в области информационных технологий с учетом социально-экономической специфики региона / А. А. Гудков, А. М. Бершадский, А. С. Бождай, Н. В. Осипова // Открытое образование. – 2008. – № 1. – С. 23–33.

Прочие публикации

2. Гудков, А. А. Автоматизированный анализ данных с использованием технологий OLAP и Data Mining / А. А. Гудков, П. А. Гудков // Технологии Microsoft в теории и практике программирования : материалы конф. / под ред. проф. Р. Г. Стронгина. – Н. Новгород : Изд-во Нижегород. гос. ун-та, 2006. – С. 85–87.

3. Гудков, А. А. Исследование возможностей SQL Server 2005 для анализа образовательных данных / А. А. Гудков // Университетское образование: сб. ст. X Междунар. науч.-метод. конф. – Пенза: ПГУ ПДЗ, 2006. – С. 363–365.

4. Гудков, А. А. Применение методов Data Mining для анализа социально-экономических статистических данных / А. А. Гудков, А. М. Бершадский, А. Г. Финогеев // Развитие университетского комплекса как фактор повышения инновационного и образовательного потенциала региона : материалы Всерос. науч.-практ. конф. Секция 11. Методологические проблемы развития статистической науки. – Оренбург : ИПК ГОУ ОГУ, 2007. – С. 16–22.

5. Гудков, А. А. Применение новых информационных технологий анализа информации в сфере образования / А. А. Гудков // Известия

Пензенского государственного педагогического университета. Сектор молодых ученых. – Пенза : ПГПУ, 2007. – № 3 (7). – С. 201–203.

6. Гудков, А. А. Построение интегральных индикаторов как инструмент мониторинга университетского образования / А. А. Гудков // Университетское образование : сб. ст. XI Междунар. науч.-метод. конф. – Пенза, 2007. – С. 175–177.

7. Гудков, А. А. Анализ социально-экономической сферы региона с использованием технологий Knowledge Discovery in Databases / А. А. Гудков, А. М. Бершадский // Информационные технологии в науке, социологии, экономике и бизнесе IT+SE'07 : материалы XXXIV Междунар. конф. Майская сессия. – Украина, Крым, Ялта–Гурзуф, 2007. – С. 94–95.

8. Гудков, А. А. Применение методов Data Mining для анализа данных образовательной статистики / А. А. Гудков, А. М. Бершадский // Телематика'2007 : тр. XIV Всерос. науч.-метод. конф. – СПб., 2007. – С. 382–384.

9. Гудков, А. А. Мониторинг региональной системы образования с использованием информационных технологий / А. А. Гудков, А. М. Бершадский, П. А. Гудков // Информационные технологии в образовании, науке и производстве : сб. тр. I Всерос. науч.-практ. конф. – Серпухов, 2007. – С. 104–107.

10. Гудков, А. А. Построение социально-экономических моделей с использованием методов Data Mining / А. А. Гудков // Аналитические и численные методы моделирования естественнонаучных и социальных проблем : сб. тр. II Междунар. конф. – Пенза, 2007. – С. 156–158.

11. Гудков, А. А. Выявление закономерностей между уровнем образования населения и социально-экономическими показателями региона с использованием технологий KDD / А. А. Гудков, А. М. Бершадский // Дистанционное и виртуальное обучение. – 2008. – № 5. – С. 29–40.

12. Гудков, А. А. Структура автоматизированной системы мониторинга на основе технологий KDD / А. А. Гудков // Новые информационные технологии в научных исследованиях и образовании : материалы XIII Всерос. науч.-техн. конф. студентов. Часть 1. – Рязань, 2008. – С. 10–12.

13. Гудков, А. А. Система поддержки принятия решений на основе технологий KDD в управлении образованием / А. А. Гудков // Университетское образование : сб. ст. XII Междунар. науч.-метод. конф. – Пенза, 2008. – С. 297–299.

14. Гудков, А. А. Технология анализа индикаторов деятельности высших учебных заведений / А. А. Гудков, А. М. Бершадский // Тематика'2008 : тр. XV Всерос. науч.-метод. конф. – СПб., 2008. – С. 442–443.

15. Гудков, А. А. Использование нейронных сетей для анализа социально-экономических данных / А. А. Гудков // Перспективные технологии искусственного интеллекта : сб. тр. науч.-практ. конф. – Пенза: Инф.-издат. центр Пенз. гос. ун-та, 2008. – С. 120–123.

16. Гудков, А. А. Изучение методологии интеллектуального анализа данных – необходимое условие подготовки квалифицированных управленцев / А. А. Гудков, А. М. Бершадский, И. П. Бурукина // Перспективные технологии искусственного интеллекта : сб. тр. науч.-практ. конф. – Пенза: Инф.-издат. центр Пенз. гос. ун-та, 2008. – С. 52–55.

Гудков Алексей Анатольевич

Автоматизированная система мониторинга
социально-экономической сферы региона
на основе технологий обнаружения знаний
в базах данных

Специальность 05.13.10 – Управление в социальных
и экономических системах (технические науки)

Редактор *Т. Н. Судовчихина*
Технический редактор *Н. А. Вьялкова*
Корректор *Н. А. Сидельникова*
Компьютерная верстка *М. Б. Жучковой*

ИД № 06494 от 26.12.01

Сдано в производство 06.11.2008. Формат 60х84¹/16.

Бумага офсетная. Печать офсетная. Усл. печ. л. 1,16.

Заказ № 624. Тираж 100.

Издательство Пензенского государственного университета.
440026, Пенза, Красная, 40.